30 dakika

14

Basit Doğrusal Regresyon

lm() ile model kurmak ve summary() çıktısını bölüm bölüm okumak

---

5 günlük program · 3. gün · 3. ders saati (çoklu regresyon ile birlikte)

Gürçay Kıvanç AKYILDIZ

Pamukkale Üniversitesi · Fen Fakültesi · Biyoloji Bölümü

DERS PLANI

30 dakikada neler yapacağız?

0–4 dk — **Korelasyondan modele**
Regresyon hangi soruyu yanıtlar?

4–11 dk — **Kendi verimiz**
Sıcaklık–oksijen: lm(), katsayılar, grafik

11–21 dk — **cars: summary() çıktısı**
Katsayı, standart hata, p, R^2, F

21–27 dk — **Tahmin ve çevresel örnek**
predict(), aralıklar, varechem P ~ K

27–30 dk — **Sorular**
Kendini sına

ÖĞRENİM KAZANIMLARI

- Sonuç ve açıklayıcı değişkeni ayırt etmek
- `lm()` ile model kurup `summary()` çıktısını okumak
- Kesişim, eğim, standart hata, p-değeri ve R^2'yi yorumlamak
- Güven aralığı ile tahmin aralığını ayırt etmek
- Sonucu nedensellik iddiası kurmadan raporlamak

PROBLEM

Korelasyon "birlikte değişiyor mu?" der; regresyon "ne kadar?"

- Korelasyonda iki değişken **eşittir**; hangisinin hangisini açıkladığı sorulmaz.
- Regresyonda bir **sonuç (y)** ve onu açıklamaya çalışan bir **açıklayıcı (x)** değişken vardır.
- Regresyon şu soruyu yanıtlar: **x 1 birim artınca y ortalama ne kadar değişir?**
- Bu bilgiyle yeni bir x değeri için **y tahmini** de yapılabilir.

Model: $y = b_0 + b_1 \cdot x + \text{hata}$

b_0 = **kesişim** (x = 0 iken beklenen y)
b_1 = **eğim** (x 1 birim artınca y'deki ortalama değişim)
hata = **artık**: gözlenen − modelin tahmini

R'de tek satır

`lm(y ~ x, data = tablo)` → "y'yi x ile açıkla"

NE ZAMAN?

Basit doğrusal regresyon hangi durumda uygun?

KOŞUL	NEDEN ÖNEMLİ?	NASIL KONTROL EDİLİR?
Sonuç değişkeni sayısal ve sürekli	Model ortalama bir y değeri tahmin eder	Veri yapısı: `str()`
İlişki yaklaşık doğrusal	Düz çizgi eğri bir ilişkiyi yanlış özetler	Saçılım grafiği (önce bak!)
Gözlemler birbirinden bağımsız	Aynı noktanın tekrarları bilgiyi şişirir	Örnekleme tasarımı
Artıklar yaklaşık sabit varyanslı ve normal	Standart hata ve p-değeri buna dayanır	16. ders: artık analizi

> Sayım (tür sayısı) veya var/yok gibi sonuçlar için doğrusal regresyon değil, **GLM** (21. ders) daha uygundur.

BÖLÜM 1

Kendi verimizle başlayalım

Su sıcaklığı arttıkça çözünmüş oksijen nasıl değişiyor?

LM()

İlk modelimiz: oksijen ~ sıcaklık

```r
# 10 akarsu istasyonu (öğretim amaçlı, simüle veri)
akarsu <- data.frame(
  sicaklik = c(6, 8, 10, 12, 14, 16, 18, 20, 22, 24),          # °C
  oksijen  = c(12.1, 11.9, 11.0, 10.9, 10.1, 9.9, 9.6, 8.9, 8.8, 8.2)  # mg/L
)

model0 <- lm(oksijen ~ sicaklik, data = akarsu)
coef(model0)     # yalnızca katsayılar
```

ÇIKTI

```
(Intercept)    sicaklik
 13.3854545  -0.2163636
```

- `oksijen ~ sicaklik` → "oksijeni sıcaklıkla açıkla". Solda **sonuç**, sağda **açıklayıcı**.
- `coef()` yalnızca kesişim ve eğimi verir.
- **Eğim = −0.216:** sıcaklık **1 °C artınca** oksijen ortalama **0.22 mg/L azalır**.
- **Kesişim = 13.39:** 0 °C'de beklenen oksijen. Verimiz 6 °C'den başladığı için bu değer yalnızca bir başlangıç noktasıdır.

GRAFİK VE TAHMİN

Doğruyu çiz, yeni bir değer için tahmin yap

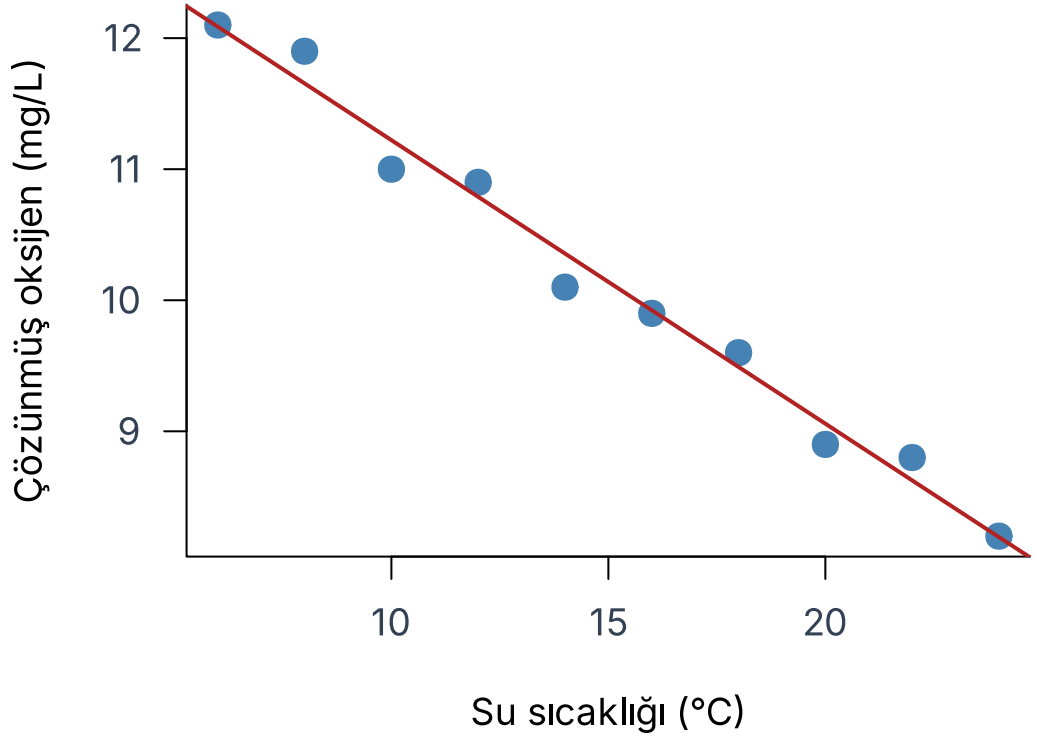
```
plot(oksijen ~ sicaklik, data = akarsu, pch = 19,
     col = "steelblue", cex = 1.5,
     xlab = "Su sıcaklığı (°C)", ylab = "Çözünmüş oksijen (mg/L)")
abline(model0, col = "firebrick", lwd = 2)   # regresyon doğrusu

predict(model0, newdata = data.frame(sicaklik = 15))
```

ÇIKTI

```
    1
10.14
```

Yorum: 15 °C'lik bir istasyonda beklenen oksijen ≈ **10.1 mg/L**.
Hesap: 13.39 + (−0.216 × 15) = 10.14



BÖLÜM 2

Çıktıyı okumak: datasets::cars

1920'lerde ölçülmüş 50 otomobil: hız (mph) arttıkça durma mesafesi (ft) ne kadar uzar?

HAZIRLIK

Veri ve merkezleme

```
data(cars)
head(cars, 3)
mean(cars$speed)

# Hızı ortalamaya göre merkezle: ortalama hız = 0
cars$speed.c <- cars$speed - mean(cars$speed)

mod1 <- lm(dist ~ speed.c, data = cars)
```

ÇIKTI

```
  speed dist
1     4    2
2     4   10
3     7    4
[1] 15.4
```

- `dist`: durma mesafesi (**sonuç**), `speed`: hız (**açıklayıcı**).
- Hız hiçbir zaman 0 değil; bu yüzden ham kesişim ("0 mph'de mesafe") anlamsızdır.
- **Merkezleme:** her hızdan ortalamayı (15.4) çıkarırız. Böylece kesişim = **ortalama hızdaki** beklenen mesafe olur.
- Merkezleme **eğimi değiştirmez**, yalnızca kesişimi anlamlı kılar.

SUMMARY()

Modelin tam çıktısı: altı bölüm

```
summary(mod1)
```

ÇIKTI

```
Call:
lm(formula = dist ~ speed.c, data = cars)

Residuals:
    Min      1Q  Median      3Q     Max
-29.069  -9.525  -2.272   9.215  43.201

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  42.9800     2.1750  19.761  < 2e-16 ***
speed.c       3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511,    Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12
```

BÖLÜM	NE ANLATIR?
① **Call**	Kurulan model formülü
② **Residuals**	Artıkların dağılımı: medyan 0'a yakın, uçlar dengeli mi?
③ **Coefficients**	Kesişim ve eğim + belirsizlikleri
④ **Residual std. error**	Tahminlerin tipik sapması (y biriminde)
⑤ **R-squared**	y'deki değişkenliğin açıklanan oranı
⑥ **F-statistic**	Model bütün olarak işe yarıyor mu?

③ COEFFİCİENTS

Katsayılar tablosunu satır satır okuyalım

SÜTUN	SPEED.C SATIRINDAKİ DEĞER	ANLAMI
Estimate	**3.93**	Hız 1 mph artınca durma mesafesi ortalama **3.9 ft** uzar
Std. Error	0.416	Eğim tahminindeki belirsizlik; küçük olması iyidir
t value	9.46	Estimate / Std. Error: eğim, belirsizliğinin kaç katı?
Pr(>|t|)	1.49e-12	Gerçek eğim 0 olsaydı bu sonucu görme olasılığı → **çok küçük**
(Intercept)	**42.98**	Ortalama hızda (15.4 mph) beklenen durma mesafesi ≈ **43 ft**

> Yıldızlar (***) yalnızca p-değerinin kısaltmasıdır. Önce **Estimate'in yönüne ve büyüklüğüne** bakın; ekolojik/pratik önem sayının kendisindedir, yıldızda değil.

④ ⑤ ⑥

Model ne kadar iyi?

Residual standard error = 15.38

Tahminler gerçek mesafeden tipik olarak **±15 ft** sapıyor. Birimi y ile aynıdır; pratik olarak yorumlanabilir.

R^2 = 0.651

Durma mesafesindeki değişkenliğin **%65**'i hız ile açıklanıyor. Geri kalan %35: sürücü, fren, yol vb.

F = 89.57, p = 1.49e-12

Model, hiçbir açıklayıcı içermeyen "sadece ortalama" modelinden **anlamlı biçimde** daha iyi.

Yüksek R^2 modelin **doğru** olduğunu kanıtlamaz: ilişki eğri olabilir, artıklarda desen olabilir. Bunlar 16. derste kontrol edilir.

PREDİCT()

Güven aralığı mı, tahmin aralığı mı?

```r
yeni <- data.frame(speed.c = 20 - mean(cars$speed))  # 20 mph

predict(mod1, newdata = yeni, interval = "confidence")
predict(mod1, newdata = yeni, interval = "prediction")
```

ÇIKTI

```
       fit      lwr      upr
1 61.06908 55.24729 66.89088
       fit      lwr      upr
1 61.06908 29.60309 92.53507
```

Güven aralığı: 55 – 67 ft

20 mph'de giden **tüm araçların ortalama** durma mesafesi bu aralıkta. Dar, çünkü ortalama daha kesin bilinir.

Tahmin aralığı: 30 – 93 ft

20 mph'de giden **tek bir aracın** mesafesi bu aralıkta. Geniş, çünkü bireysel değişkenliği de içerir.

Tahmin, verinin aralığı (4–25 mph) içinde yapılmalı; aralık dışına çıkmak (ekstrapolasyon) güvenilmezdir.

ÇEVRESEL ÖRNEK

varechem: toprak potasyumu fosforu açıklıyor mu?

```
library(vegan)
data(varechem)

env_model <- lm(P ~ K, data = varechem)
summary(env_model)
```

ÇIKTI

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 16.75930    5.64386   2.969  0.00708 **
K            0.17382    0.03228   5.385 2.08e-05 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

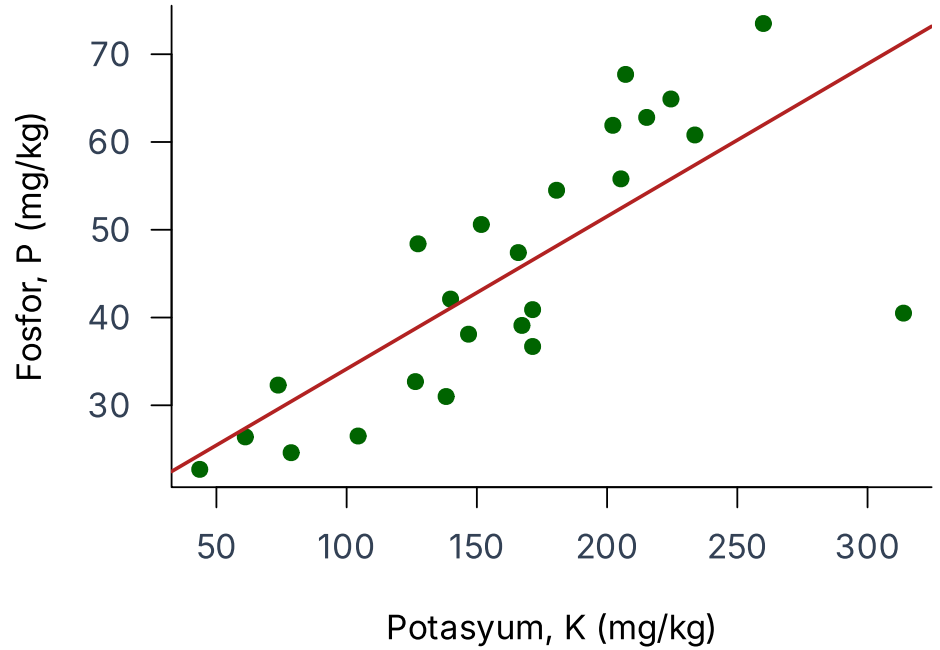
Residual standard error: 10.04 on 22 degrees of freedom
Multiple R-squared:  0.5686,    Adjusted R-squared:  0.549
F-statistic:    29 on 1 and 22 DF,  p-value: 2.084e-05
```

- **Eğim = 0.174:** K **1 mg/kg** arttıkça P ortalama **0.17 mg/kg** artıyor (100 mg/kg K artışı ≈ +17 mg/kg P).
- p = 2.08e-05 → eğimin 0 olduğu varsayımıyla bu veri pek uyumlu değil.
- **R^2 = 0.57:** P'deki değişkenliğin yarıdan fazlası K ile birlikte değişiyor.
- RSE = 10 mg/kg: tahminler tipik olarak ±10 mg/kg sapıyor.
- K ve P birlikte artıyor; ama bu **gözlemsel** veri. K'nın P'yi artırdığını **göstermez** (ortak etken: toprak tipi, ayrışma).

RAPORLAMA

Grafik + bir cümle

```
plot(P ~ K, data = varechem, pch = 19, col = "darkgreen",
     xlab = "Potasyum, K (mg/kg)", ylab = "Fosfor, P (mg/kg)")
abline(env_model, col = "firebrick", lwd = 2)
```



> Toprak fosforu, potasyumla pozitif ve anlamlı bir doğrusal ilişki göstermiştir (b = 0.17 mg/kg P / mg/kg K, SE = 0.03, p < 0.001, R^2 = 0.57, n = 24). Bulgu gözlemsel olup nedensel bir etki olarak yorumlanmamalıdır.

- Eğimi **birimiyle** birlikte verin.
- SE, p, R^2 ve n'yi ekleyin.
- Modeli kurmadan önce grafiğe, kurduktan sonra artıklara bakın.

KENDİNİ SINA

Ölçme ve değerlendirme

1. `dist ~ speed.c` formülünde sonuç ve açıklayıcı değişken hangileridir?
2. Eğim katsayısı (3.93) cümle olarak nasıl yorumlanır?
3. Standart hata, t değeri ve p-değeri neyi özetler?
4. R^2 neyi gösterir, neyi kanıtlamaz?
5. Güven aralığı neden tahmin aralığından daha dardır?

ÖZET

Akılda kalması gerekenler

- `lm(y ~ x, data = ...)` → y'yi x ile açıklayan doğrusal model.
- **Eğim**: x 1 birim artınca y'deki ortalama değişim (birimiyle yorumla!).
- `summary()`: Coefficients → R^2 → RSE → F sırasıyla oku.
- `predict(..., interval = "confidence" / "prediction")`: ortalama vs tek gözlem.
- Gözlemsel veride regresyon **ilişkiyi** ölçer, nedeni kanıtlamaz.