30 dakika

16

Artık Analizi

Model çıktısına güvenmeden önce: doğrusallık, sabit varyans, normallik ve etkili gözlemler

---

5 günlük program · 3. gün · 4. ders saati
Gürçay Kıvanç AKYILDIZ
Pamukkale Üniversitesi · Fen Fakültesi · Biyoloji Bölümü

DERS PLANI

30 dakikada neler yapacağız?

0–4 dk — **Artık nedir, neden bakarız?**
Dört varsayım ve R araç kutusu

4–12 dk — **Doğrusallık: airquality**
U biçimli artık ve log dönüşümüyle çözüm

12–17 dk — **Sabit varyans: cars**
Huni biçimi ve karekök dönüşümü

17–25 dk — **Etkili gözlem: mtcars, varechem**
Kaldıraç, Cook uzaklığı, duyarlılık analizi

25–30 dk — **Karar tablosu ve sorular**
Sorun → çözüm, raporlama

ÖĞRENİM KAZANIMLARI

- Artığın modeldeki anlamını açıklamak
- `plot(model, which = )` ile tanı grafiklerini seçerek üretmek
- Doğrusallık ve sabit varyans sorunlarını fark edip dönüşümle düzeltmek
- Kaldıraç ve Cook uzaklığını eşik değerlerle değerlendirmek
- Etkili gözlemi silmeden duyarlılık analiziyle raporlamak

PROBLEM

summary() güzel görünüyor; ama model veriye gerçekten uyuyor mu?

- **Artık** = gözlenen − modelin tahmini (`residuals()`).
- Regresyondaki standart hata, güven aralığı ve p-değerleri **varsayımlara** dayanır.
- Varsayımları kontrol etmenin yolu artıklara bakmaktır.
- İyi modelde artıklar **desensiz** ve rastgeledir; desen varsa model bir şeyi kaçırıyordur.

> Bu derste yalnızca R'ın **hazır veri setlerini** kullanıyoruz: `airquality` , `cars` , `mtcars` (datasets) ve `varechem` (vegan).

VARSAYIM	BOZULURSA NE OLUR?
Doğrusallık	Katsayılar sistematik olarak yanlış
Bağımsızlık	p-değerleri aşırı iyimser
Sabit varyans	Standart hatalar güvenilmez
Normallik	Küçük örneklemde aralıklar yanlış

R ARAÇ KUTUSU

Bu derste kullanacağımız fonksiyonlar

FONKSİYON	NE YAPAR?	İSTATİSTİKSEL ANLAMI
`residuals(m)`, `fitted(m)`	Artıklar ve tahminler	Gözlenen – tahmin
`rstandard(m)`	Standartlaştırılmış artık	|değer| > 2 → sıra dışı gözlem adayı
`plot(m, which = 1)`	Residuals vs Fitted	Doğrusallık
`plot(m, which = 2 / 3)`	Q-Q / Scale-Location	Normallik / sabit varyans
`plot(m, which = 5)`	Residuals vs Leverage	Etkili gözlem (Cook çizgileri)
`hatvalues(m)`	Kaldıraç	Eşik ≈ 2p / n (p = katsayı sayısı)
`cooks.distance(m)`	Cook uzaklığı	> 4/n dikkat, > 1 güçlü etki
`update(m, data = ...)`	Modeli farklı veriyle yeniden kur	Duyarlılık analizi

BÖLÜM 1

Doğrusallık: datasets::airquality

New York, 1973 yazı: hava sıcaklığı (Temp, °F) ile ozon derişimi (Ozone, ppb)

AİRQUALİTY

Doğru, verinin biçimine uyuyor mu?

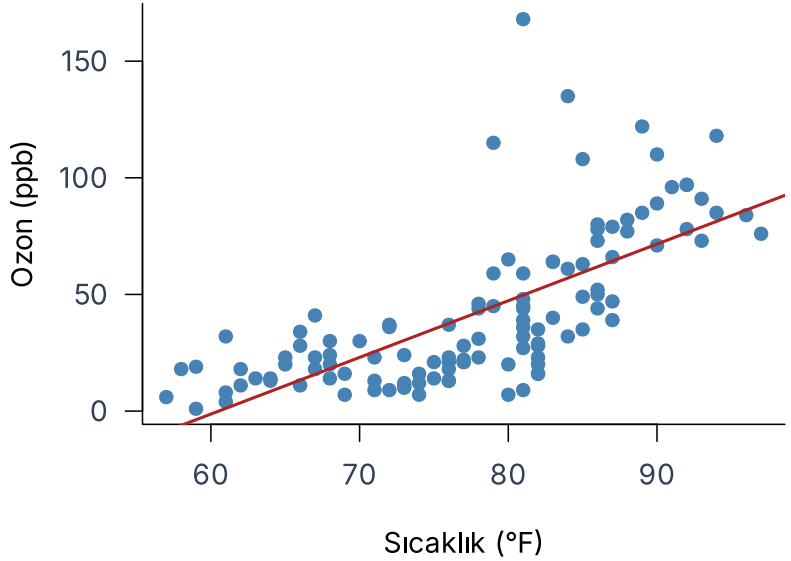
```
hava <- na.omit(airquality[, c("Ozone", "Temp")])   # eksik günleri çıkar
nrow(hava)

m1 <- lm(Ozone ~ Temp, data = hava)
summary(m1)$r.squared
```

ÇIKTI

```
[1] 116
[1] 0.4877072
```

```
plot(Ozone ~ Temp, data = hava, pch = 19, col = "steelblue",
     xlab = "Sıcaklık (°F)", ylab = "Ozon (ppb)")
abline(m1, col = "firebrick", lwd = 2)
```

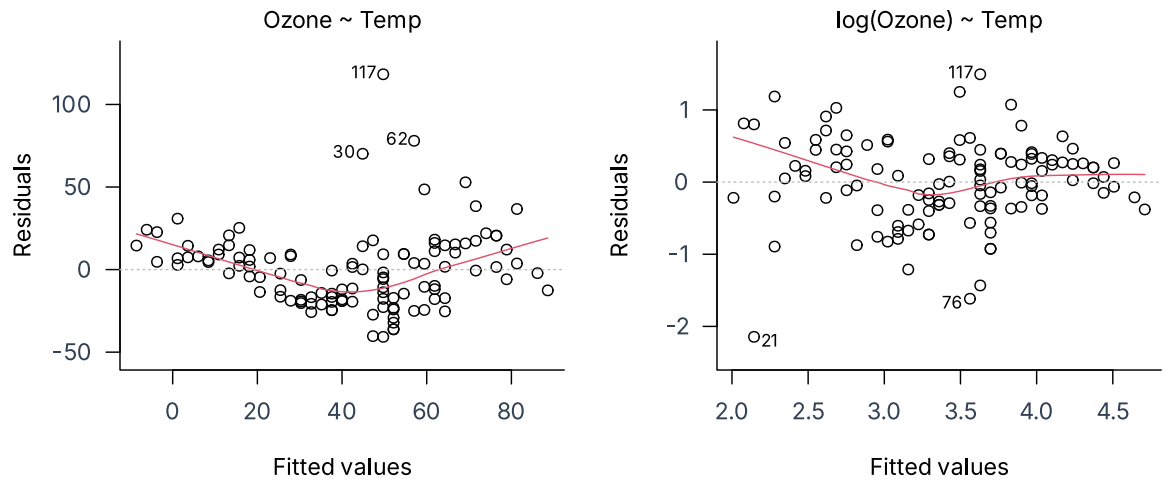


Dikkatli bakın: düşük ve yüksek sıcaklıklarda noktalar doğrunun **üstünde**, ortada **altında**. Ozon sıcaklıkla doğrusal değil, **hızlanarak** artıyor; sıcak günlerde yayılım da büyüyor.

U biçimli artık → dönüşüm → desensiz artık

```
m2 <- lm(log(Ozone) ~ Temp, data = hava)   # yanıtı log dönüştür

par(mfrow = c(1, 2))
plot(m1, which = 1, caption = "Ozone ~ Temp")
plot(m2, which = 1, caption = "log(Ozone) ~ Temp")
```




```
round(coef(m2), 3)
exp(coef(m2)["Temp"])        # çarpan
summary(m2)$r.squared
```

ÇIKTI

```
(Intercept)        Temp
     -1.838       0.068
    Temp
1.069833
[1] 0.5473353
```

- **Solda:** kırmızı çizgi belirgin **U** → doğrusallık bozuk.
- **Sağda:** log modelde çizgi düze yakın → sorun büyük ölçüde çözüldü.
- Eğim **0.068**, exp(0.068) = **1.07**: sıcaklık 1 °F artınca ozon yaklaşık **%7** artar (çarpımsal yorum).
- R^2 0.49 → 0.55: asıl kazanç R^2 değil, **doğru biçim**.

BÖLÜM 2

Sabit varyans: datasets::cars

Hız arttıkça durma mesafesinin belirsizliği de artıyor mu?

SCALE-LOCATİON

Huni biçimi: yayılım tahminle birlikte büyüyor

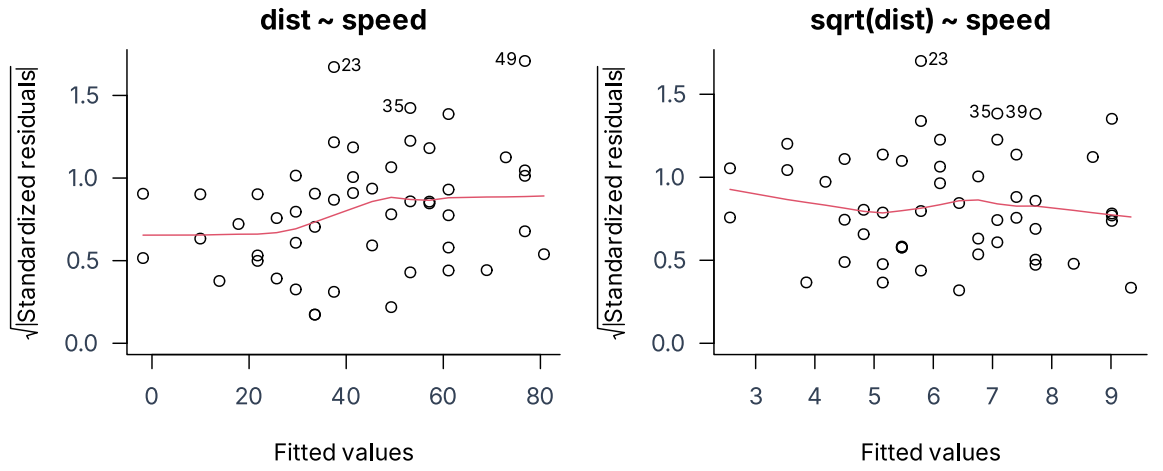
```r
mc <- lm(dist ~ speed, data = cars)
ms <- lm(sqrt(dist) ~ speed, data = cars)   # karekök dönüşümü

# Sayısal kontrol: |artık| tahminle birlikte büyüyor mu?
cor(abs(residuals(mc)), fitted(mc))
cor(abs(residuals(ms)), fitted(ms))

par(mfrow = c(1, 2))
plot(mc, which = 3, caption = "", main = "dist ~ speed")
plot(ms, which = 3, caption = "", main = "sqrt(dist) ~ speed")
```

ÇIKTI

```
[1] 0.2848836
[1] -0.00942626
```



- Ham modelde kırmızı çizgi **yükseliyor**; |artık| ile tahmin arasındaki korelasyon **0.28**.
- Karekök dönüşümünden sonra çizgi düzleşiyor; korelasyon **≈ 0**.
- Sayım ya da mesafe gibi pozitif değişkenlerde varyansın ortalamayla artması **olağandır**.

BÖLÜM 3

Normallik ve etkili gözlemler

Tek bir gözlem modeli ne kadar değiştirebilir?

mtcars: kaldıraç ile etki aynı şey değildir

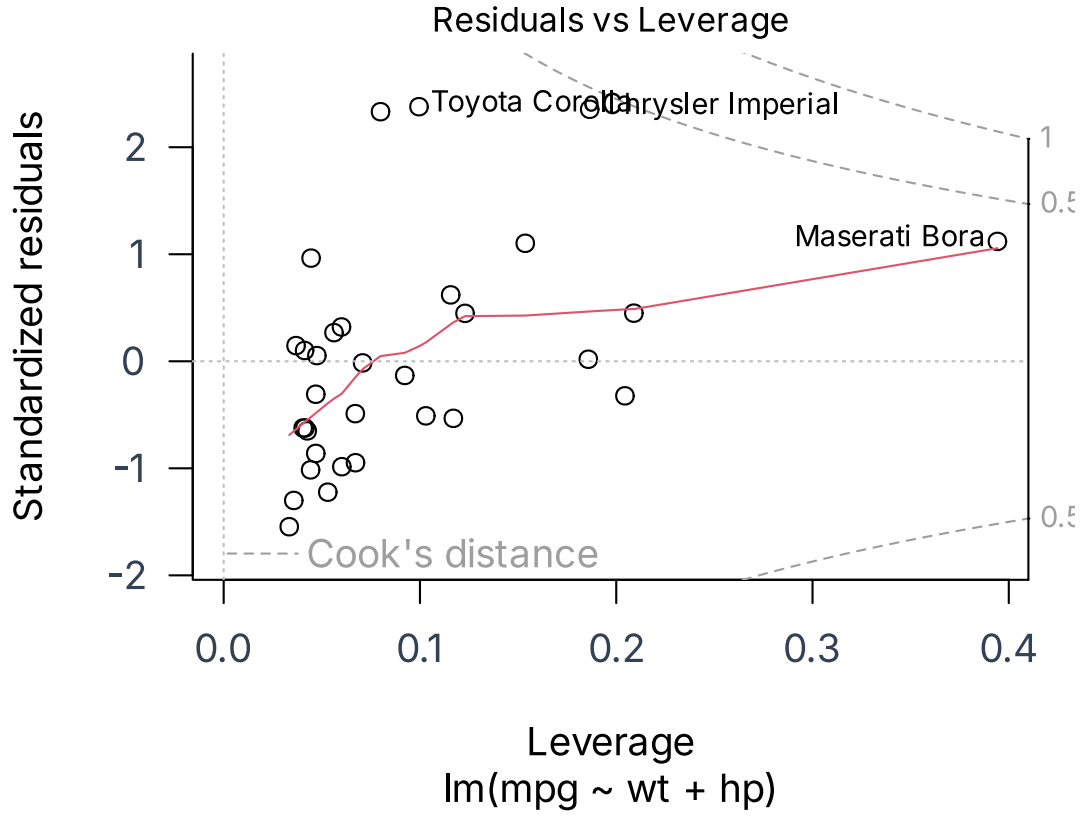
```
mt <- lm(mpg ~ wt + hp, data = mtcars)
n <- nrow(mtcars); p <- length(coef(mt))     # 32 araç, 3 katsayı

names(which(abs(rstandard(mt)) > 2))         # sıra dışı artık
round(head(sort(hatvalues(mt), decreasing = TRUE), 2), 2)
2 * p / n                                    # kaldıraç eşiği
round(head(sort(cooks.distance(mt), decreasing = TRUE), 2), 2)
```

ÇIKTI

```
[1] "Chrysler Imperial" "Fiat 128"          "Toyota Corolla"
      Maserati Bora Lincoln Continental
               0.39                0.21
[1] 0.1875
Chrysler Imperial     Maserati Bora
             0.42              0.27
```

- **Maserati Bora**: en yüksek kaldıraç (**0.39** > eşik **0.19**): beygir gücü (335 hp) diğer araçlardan çok uzak.
- **Chrysler Imperial**: kaldıracı orta, ama artığı büyük (beklenenden çok daha yüksek mpg) → en büyük Cook (**0.42**).
- Etki = kaldıraç × artık büyüklüğü: **ikisi birlikte** yüksekse gözlem modeli çeker.



NORMALLİK

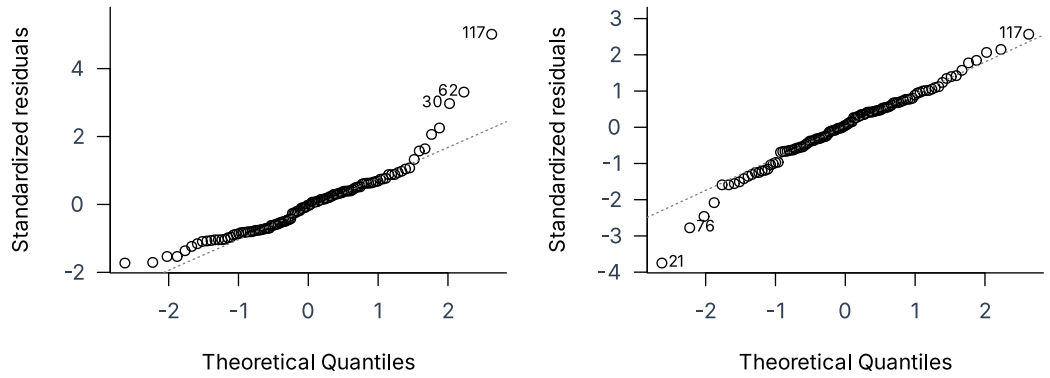
Tek bir dönüşüm, birden çok sorunu birlikte çözebilir

```
shapiro.test(residuals(m1))$p.value   # Ozone ~ Temp
shapiro.test(residuals(m2))$p.value   # log(Ozone) ~ Temp

par(mfrow = c(1, 2))
plot(m1, which = 2, caption = "Ozone ~ Temp")
plot(m2, which = 2, caption = "log(Ozone) ~ Temp")
```

ÇIKTI

```
[1] 1.141857e-07
[1] 0.05865292
```



Shapiro–Wilk testi

H_0: artıklar normal dağılımdan geliyor. Ham modelde p < 0.001 → **normallikten sapma** var. Log modelde p = 0.06 → sapmaya dair güçlü kanıt yok.

Sıra önemli

Q-Q grafiğinde sağ kuyruktaki sapma, log dönüşümünden sonra büyük ölçüde kayboldu. Normallik çoğu zaman **doğrusallık ve varyans düzelince** kendiliğinden düzelir.

Örneklem büyüklüğü tuzağı

n küçükse test sorunu kaçırır; n büyükse önemsiz sapmaları "anlamlı" bulur. **Q-Q grafiği** testten önce gelir.

varechem: 13 numaralı alan sonucu değiştiriyor

```
library(vegan); data(varechem)
env_model <- lm(P ~ K + Ca + Mg, data = varechem)
round(head(sort(cooks.distance(env_model), decreasing = TRUE), 2), 2)

model_13siz <- update(env_model,
                      data = varechem[rownames(varechem) != "13", ])
round(cbind(tum_veri = coef(env_model),
            alan13_yok = coef(model_13siz)), 3)
```

ÇIKTI

```
  13   24
2.54 0.79
            tum_veri alan13_yok
(Intercept)   12.694      7.360
K              0.113      0.225
Ca             0.030      0.002
Mg            -0.038      0.017
```

- Alan 13: Cook = **2.54** (> 1): modeldeki en etkili gözlem.
- Bu alanda **K en yüksek** (313.8) ama P ortalamanın altında.
- Alan çıkarılınca K'nın katsayısı **0.11 → 0.22**, Ca'nınki **0.03 → 0.002**.
- "Ca fosforla ilişkilidir" sonucu **tek bir alana** dayanıyor.

> `update()` modeli yeni veriyle yeniden kurar. Doğru yaklaşım silmek değil, **iki sonucu da raporlamaktır**.

KARAR TABLOSU

Tanıdan çözüme

GÖZLENEN	HANGİ GRAFİK?	OLASI ÇÖZÜM
U biçimi	`which = 1`	Dönüşüm (`log()`), `poly(x, 2)`, eksik açıklayıcı
Huni biçimi	`which = 3`	`sqrt(y)`, `log(y)`; sayım ise **GLM** (21. ders)
Uçlarda Q-Q sapması	`which = 2`	Önce 1 ve 3'ü düzelt; aykırı gözlemleri incele
Cook > 1, yüksek kaldıraç	`which = 5`	Veri kontrolü + `update()` ile duyarlılık analizi
Bağımlı gözlemler	Tasarım	Karma modeller, bloklu permütasyon (ileri konu)

Rapor cümlesi: "Ozon–sıcaklık modelinin artıkları belirgin bir eğrilik ve sağa çarpıklık gösterdiğinden ozon log-dönüştürülmüştür; dönüştürülmüş modelde artık deseni büyük ölçüde ortadan kalkmıştır (R^2 = 0.55, Shapiro p = 0.06, n = 116)."

KENDİNİ SINA

Ölçme ve değerlendirme

1. Ozon–sıcaklık modelinde artıklardaki U biçimi neyi gösterir, nasıl düzeltildi?
2. `plot(m, which = 3)` hangi varsayımı kontrol eder? Huni biçimi neyi gösterir?
3. Maserati Bora en yüksek kaldıraca, Chrysler Imperial en büyük Cook uzaklığına sahip. Neden?
4. Shapiro testinde p = 0.06 çıkması artıkların normal olduğunu kanıtlar mı?
5. Etkili bir gözlem neden silinmez, nasıl raporlanır?

ÖZET

Akılda kalması gerekenler

- Artık = gözlenen − tahmin; iyi modelde **desensizdir**.
- `plot(m, which = 1/2/3/5)`: doğrusallık, normallik, varyans, etkili gözlem.
- R^2 tek başına doğru biçimi göstermez: önce **artık grafiğine** bak (airquality örneği).
- Dönüşüm (`log`, `sqrt`) sorunları çoğu zaman çözer; sonra artıklara **yeniden** bak.
- Cook > 1 → `update()` ile duyarlılık analizi; silme değil, raporlama.