30 dakika

18

Temel Bileşenler Analizi (PCA)

14 toprak değişkenini birkaç bileşende özetlemek, kaç bileşen tutulacağına karar vermek ve skorları kullanmak

---

5 günlük program · 4. gün · 1. ders saati (CA ile birlikte)

Gürçay Kıvanç AKYILDIZ

Pamukkale Üniversitesi · Fen Fakültesi · Biyoloji Bölümü

DERS PLANI

30 dakikada neler yapacağız?

0–4 dk — **Neden PCA?**
Çok değişken, birlikte değişim, boyut indirgeme

4–10 dk — **Veri ve ölçek: varechem**
Varyanslar, korelasyon, standardizasyon

10–20 dk — **PCA'yı kurmak ve okumak**
summary, kaç eksen? (broken stick), yükler, biplot

20–26 dk — **Skorları kullanmak**
PC1'i bir toprak indeksine çevirip türlerle ilişkilendirme

26–30 dk — **Eksik veri, raporlama, sorular**
airquality ve yorum hataları

ÖĞRENİM KAZANIMLARI

- PCA'nın hangi veri için uygun olduğunu açıklamak
- Standardizasyon kararını varyanslara bakarak vermek
- `prcomp()` ve `vegan::rda()` çıktılarını okumak
- Kaç bileşenin anlamlı olduğuna broken stick ile karar vermek
- PC skorlarını başka bir analizde açıklayıcı olarak kullanmak

PROBLEM

24 alanda 14 toprak değişkeni: hepsine birden nasıl bakarız?

- Çevresel veride çok sayıda **sürekli** değişken ölçülür ve bunlar çoğu zaman **birlikte** değişir.
- 14 değişkenin 91 ikili korelasyonuna tek tek bakmak pratik değildir.
- **PCA**, değişkenlerin **doğrusal bileşimlerinden** yeni, birbiriyle **ilişkisiz** eksenler kurar.
- **PC1** en büyük varyansı, PC2 kalan en büyük varyansı taşır; ilk birkaç bileşen çoğu bilgiyi özetler.

Çıktının üç parçası

Özdeğer: bileşenin taşıdığı varyans. **Yük (loading)**: değişkenin bileşene katkısı. **Skor**: her alanın yeni eksendeki konumu.

PCA mı, CA mı?

Sürekli, doğrusal ilişkili ölçümler → **PCA**. Çok sıfırlı tür bolluk tablosu → **CA** (17. ders).

R ARAÇ KUTUSU

Bu derste kullanacağımız fonksiyonlar

FONKSİYON	NE YAPAR?
`prcomp(x, scale. = TRUE)`	Standardize PCA (temel R)
`summary(pca)`	Standart sapma, varyans payı, birikimli pay
`pca$rotation` / `pca$x`	Yükler (değişkenler) / skorlar (alanlar)
`rda(x, scale = TRUE)`	vegan ile aynı PCA (formülsüz rda)
`screeplot(m, bstick = TRUE)`	Özdeğer grafiği + broken stick beklentisi
`bstick(m)`	Rastgele bölünme altında beklenen özdeğerler
`scores(m, display = "sites")`	Alan skorlarını matris olarak alır
`biplot(m)`	Alanlar + değişken okları

BÖLÜM 1

Veri ve ölçek: vegan::varechem

Finlandiya'da 24 çam ormanı alanı: N, P, K, Ca, Mg, S, Al, Fe, Mn, Zn, Mo, çıplak toprak, humus derinliği, pH

ÖLÇEK VE İLİŞKİ

Değişkenler çok farklı ölçekte, ama güçlü birlikte değişiyor

```
library(vegan)
data(varechem)
dim(varechem)
round(sapply(varechem, var), 2)   # her değişkenin varyansı
```

ÇIKTI

```
[1] 24 14
       N        P        K       Ca       Mg        S       Al       Fe
   30.56   223.39  4204.53 59332.17  1681.93   136.14 14962.28  3654.07
      Mn       Zn       Mo Baresoil Humdepth       pH
 1149.98     8.90     0.06   270.26     0.44     0.05
```

```
r <- cor(varechem)
round(r[c("P", "K", "Ca", "Mg"), c("P", "K", "Ca", "Mg")], 2)
```

ÇIKTI

```
      P    K   Ca   Mg
P  1.00 0.75 0.74 0.60
K  0.75 1.00 0.66 0.63
Ca 0.74 0.66 1.00 0.80
Mg 0.60 0.63 0.80 1.00
```

- Ca'nın varyansı ≈ **59 000**, pH'ınki **0.05**: fark tamamen **birimlerden** (mg/kg, pH birimi, cm).
- Standardize edilmezse PCA neredeyse yalnızca **Ca, K, Mg, Al**'u görür.
- P, K, Ca, Mg birbirleriyle **0.6–0.8** düzeyinde ilişkili → bunlar ortak bir eksende toplanacak.
- Bu birlikte değişim PCA'nın **var olma nedenidir**.

> Kural: farklı birimler → `scale. = TRUE` . Bu, PCA'yı **kovaryans** yerine **korelasyon** matrisi üzerinden yapmak demektir.

STANDARDİZASYON

scale. = TRUE sonucu nasıl değiştiriyor?

```
pca_ham <- prcomp(varechem, scale. = FALSE)
pca_std <- prcomp(varechem, scale. = TRUE)

round(summary(pca_ham)$importance[2, 1:3], 3)   # ham
round(summary(pca_std)$importance[, 1:5], 3)    # standardize
```

ÇIKTI

```
  PC1   PC2   PC3
0.748 0.198 0.028
                          PC1   PC2   PC3   PC4   PC5
Standard deviation     2.278 1.787 1.298 1.034 0.903
Proportion of Variance 0.371 0.228 0.120 0.076 0.058
Cumulative Proportion  0.371 0.599 0.719 0.796 0.854
```

Ham PCA: PC1 = %74.8

Tek bileşen "çok güçlü" görünüyor; ama bu yalnızca Ca'nın büyük sayılarıdır. **Yanıltıcı.**

Standardize PCA: PC1 = %37.1, PC2 = %22.8

Her değişken eşit ağırlıkta. Bilgi birden çok bileşene dağılmış: ilk iki bileşen **%60**, ilk dört **%80**.

- **Standard deviation²** = özdeğer. Standardize PCA'da özdeğerlerin toplamı = değişken sayısı (**14**).

BÖLÜM 2

Kaç bileşen? Ne anlama geliyorlar?

Broken stick, yükler ve biplot

KAÇ EKSEN?

Broken stick: rastgele bölünmeden daha fazlasını taşıyan eksenler

```
pca <- rda(varechem, scale = TRUE)     # vegan ile aynı PCA

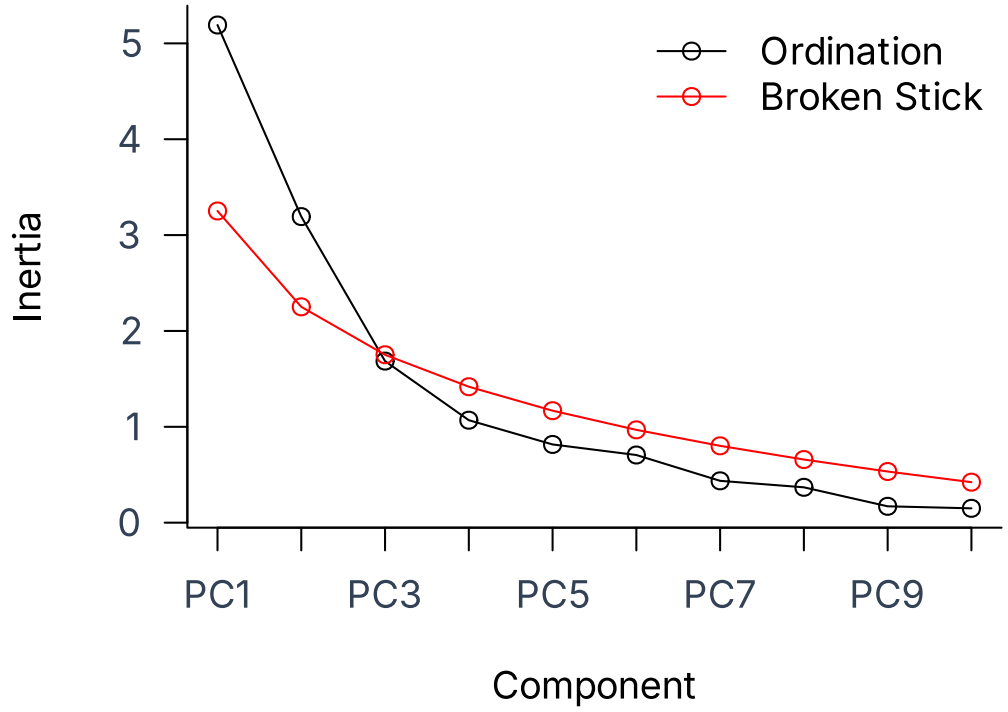
round(eigenvals(pca)[1:5], 2)          # gözlenen özdeğerler
round(bstick(pca)[1:5], 2)             # rastgele beklenen

screeplot(pca, bstick = TRUE, type = "lines", main = "")
```

ÇIKTI

```
 PC1  PC2  PC3  PC4  PC5
5.19 3.19 1.69 1.07 0.82
 PC1  PC2  PC3  PC4  PC5
3.25 2.25 1.75 1.42 1.17
```

- **Broken stick**: toplam varyans rastgele parçalara bölünseydi her eksenin beklenen payı.
- PC1 (5.19 > 3.25) ve PC2 (3.19 > 2.25) beklentiyi **aşıyor**; PC3 (1.69 < 1.75) aşmıyor → **2 bileşen** yorumlanır.
- **Kaiser kuralı** (özdeğer > 1) 4 bileşen önerir; daha **cömert** bir kuraldır.



YÜKLER

Bileşenleri adlandırmanın anahtarı

```
yuk <- scores(pca, display = "species", choices = 1:2, scaling = 0)
round(yuk[order(yuk[, 1]), ], 2)       # PC1'e göre sıralı
```

ÇIKTI

```
            PC1   PC2
K         -0.36 -0.16
Ca        -0.36 -0.08
P         -0.36 -0.21
Mg        -0.35 -0.10
Zn        -0.35 -0.16
S         -0.33 -0.30
Mn        -0.29  0.19
Humdepth  -0.24  0.34
Baresoil  -0.16  0.32
Mo        -0.04 -0.23
N          0.09  0.12
Al         0.12 -0.48
pH         0.17 -0.32
Fe         0.20 -0.38
```

- `scaling = 0`: ölçeklenmemiş **yükler** (özvektörler).
- **PC1:** P, K, Ca, Mg, Zn, S hepsi **−0.33 / −0.36** → negatif yön = **besince zengin** toprak.
- **PC2:** Al (−0.48), Fe, pH bir yanda; Humdepth (+0.34), Baresoil (+0.32) diğer yanda → **mineral toprak – humus katmanı** karşıtlığı.
- N ve Mo'nun iki bileşende de yükü küçük: bu iki eksende **iyi temsil edilmiyorlar**.

> İşaret keyfidir: tüm yükler −1 ile çarpılsa analiz değişmez. Önemli olan değişkenlerin **birbirine göre** yönüdür.

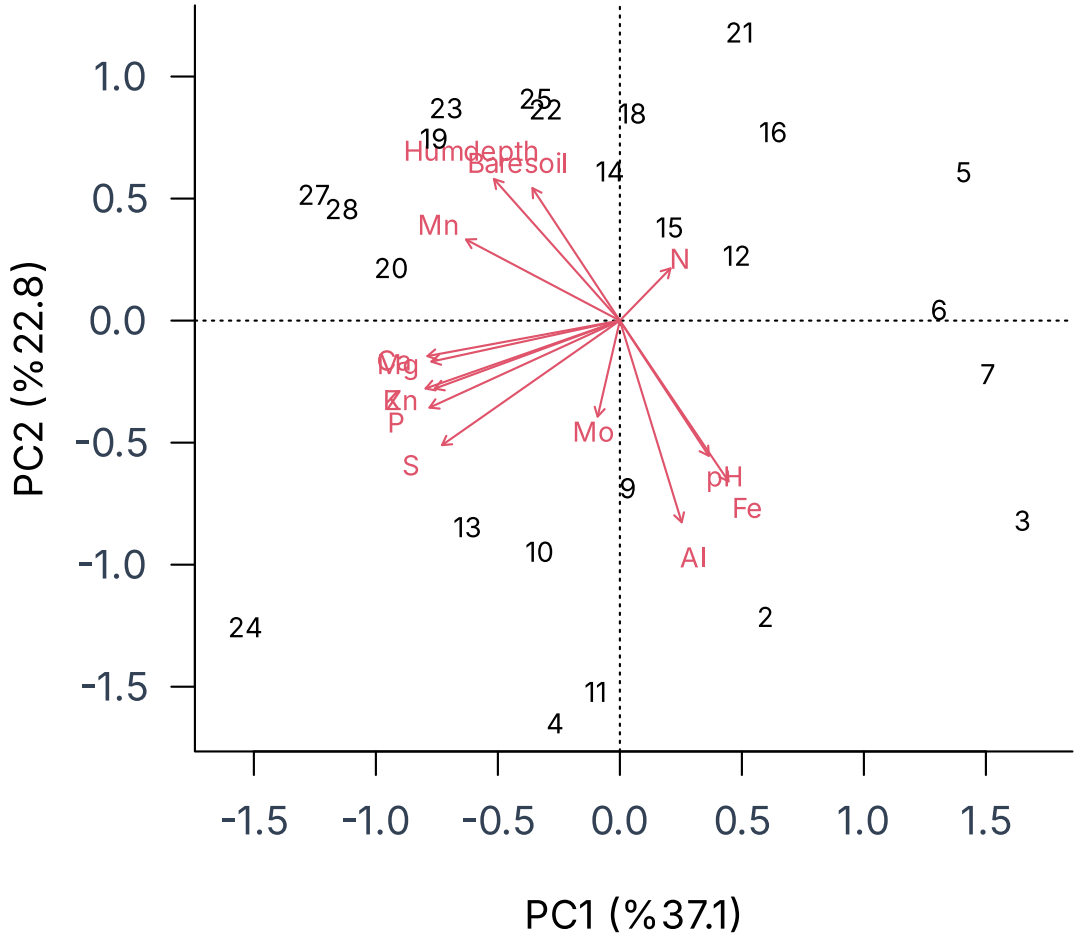
BİPLOT

Noktalar alanlar, oklar değişkenler

```
biplot(pca, scaling = 2, main = "",
       xlab = "PC1 (%37.1)", ylab = "PC2 (%22.8)")
```

ÖĞE	NASIL OKUNUR?
Ok yönü	Değişkenin arttığı yön
Ok uzunluğu	Bu iki eksende ne kadar iyi temsil edildiği
Oklar arası açı	Dar: pozitif ilişki · 90°: ilişkisiz · 180°: negatif
Nokta–ok	Alanın o değişkendeki göreli değeri (ok yönüne izdüşüm)

- Besin okları (P, K, Ca, Mg…) **aynı yöne** bakıyor; sol taraftaki alanlar besince zengin.



BÖLÜM 3

Skorları kullanmak

PC1'i bir "toprak verimliliği indeksi" olarak kullanıp bir yosun türünün örtüsüyle karşılaştıralım

PC SKORU → YENİ ANALİZ

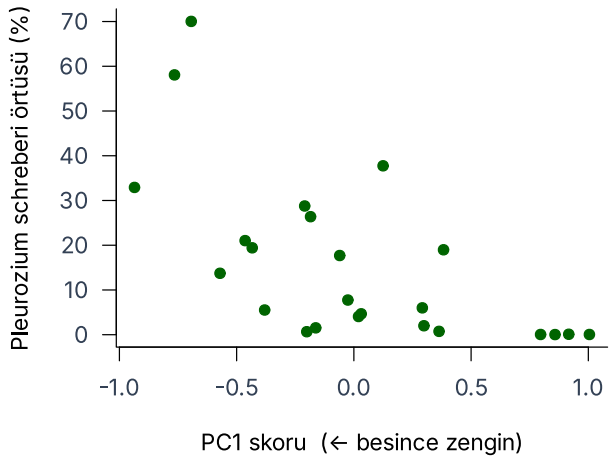
14 değişken yerine tek bir indeks

```
data(varespec)                                  # aynı 24 alanda bitki örtüsü
pc1 <- scores(pca, display = "sites", choices = 1, scaling = 1)[, 1]

cor.test(pc1, varespec$Pleuschr, method = "spearman", exact = FALSE)
```

ÇIKTI

```
S = 3957.4, p-value = 7.14e-05
alternative hypothesis: true rho is not equal to 0
sample estimates:
       rho
-0.7205914
```



- `scores(..., display = "sites")` her alanın PC1 değerini verir: 14 değişkenin **özeti**.
- Yosun *Pleurozium schreberi* örtüsü PC1 ile **güçlü negatif** ilişkili ($\rho = -0.72$, $p < 0.001$).
- Yani yosun **besince zengin** (PC1 negatif) alanlarda daha bol.
- Avantaj: 14 ayrı test yerine **tek test** → çoklu test sorunu azalır, çoklu bağlantı ortadan kalkar.

> Dezavantaj: PC1 bir **bileşimdir**; hangi tek değişkenin önemli olduğunu söylemez. Doğrudan topluluk–çevre modeli için → **RDA/CCA** (19–20. ders).

EKSİK VERİ

prcomp() NA kabul etmez: kaybı görün ve raporlayın

```
air <- airquality[, c("Ozone", "Solar.R", "Wind", "Temp")]
colSums(is.na(air))         # hangi değişkende kaç NA?
nrow(air); nrow(na.omit(air))

pca_air <- prcomp(na.omit(air), scale. = TRUE)
round(summary(pca_air)$importance[2:3, ], 2)
```

ÇIKTI

```
  Ozone Solar.R    Wind    Temp
     37       7       0       0
[1] 153
[1] 111
                          PC1  PC2  PC3  PC4
Proportion of Variance 0.59 0.22 0.12 0.07
Cumulative Proportion  0.59 0.81 0.93 1.00
```

- `colSums(is.na())`: NA'ların çoğu **Ozone**'da (37) ve Solar.R'da (7).
- `na.omit()` ile 153 günden **111** gün kalıyor: verinin **%27'si** kayıp.
- Kalan veride PC1 %59, ilk iki bileşen %81 açıklıyor.

> Kayıp rastgele değilse (örn. ölçüm cihazı yalnızca bulutlu günlerde arızalanıyorsa) PCA sonucu **yanlı** olur. Kaç gözlemin neden çıkarıldığını mutlaka yazın.

RAPORLAMA

PCA sonucunu nasıl yazarız?

Toprak kimyası (24 alan × 14 değişken) değişkenler standardize edilerek PCA ile özetlenmiştir (`vegan::rda` , `scale = TRUE`). Broken stick ölçütüne göre iki bileşen yorumlanmıştır: PC1 (%37.1) besin elementleri (P, K, Ca, Mg, Zn, S) gradyanını, PC2 (%22.8) Al–Fe ile humus derinliği karşıtlığını yansıtmıştır. PC1 skorları yosun *Pleurozium schreberi* örtüsüyle negatif ilişkilidir (Spearman ρ = −0.72, p < 0.001).

"PC1 = Ca"

Bileşen tek değişken değildir; **yüklere** bakarak temkinli adlandır.

"%60 açıklandı"

Açıklanan varyans istatistikseldir; **hangi değişkenleri seçtiğin** sonucu belirler.

"Bu desen nedensel"

PCA bir **özettir**: test etmez, neden göstermez.

KENDİNİ SINA

Ölçme ve değerlendirme

1. varechem'de standardize edilmemiş PCA'da PC1 neden %74.8 çıktı?
2. Broken stick ve Kaiser kuralı neden farklı sayıda bileşen öneriyor?
3. Bir yükün işareti (+/−) tek başına yorumlanabilir mi? Neden?
4. Biplotta iki ok arasındaki açı 90° ise ne söylenebilir?
5. PC1 skorlarını başka bir analizde kullanmanın avantajı ve sınırı nedir?

ÖZET

Akılda kalması gerekenler

- Farklı birimler → `scale. = TRUE`: PCA korelasyon matrisi üzerinden çalışır.
- `summary()` → varyans payları; `bstick()` / `screeplot(bstick = TRUE)` → **kaç bileşen**.
- Yükler (`$rotation`, `scaling = 0`) bileşeni adlandırır; işaret keyfidir.
- Skorlar (`$x`, `scores()`) çok değişkenli bir **indeks** olarak kullanılabilir.
- NA kaybını ve standardizasyon kararını her zaman raporla.