30 dakika

21

Genelleştirilmiş Doğrusal Modeller (GLM)

Sayım ve var/yok verisini doğru dağılımla modellemek: Poisson, negatif binom ve lojistik regresyon

---

5 günlük program · 5. gün · 1. ders saati (AIC ile birlikte)

Gürçay Kıvanç AKYILDIZ

Pamukkale Üniversitesi · Fen Fakültesi · Biyoloji Bölümü

DERS PLANI

30 dakikada neler yapacağız?

0–4 dk — **Neden lm() yetmez?**
Sayım ve var/yok verisinin özellikleri

4–8 dk — **GLM'nin üç parçası**
Dağılım, bağlantı fonksiyonu, doğrusal öngörücü

8–20 dk — **Poisson GLM: BCI**
Katsayı → oran, sapma (deviance), LRT, aşırı saçılma

20–26 dk — **Lojistik GLM: mite**
Var/yok verisi, odds oranı, olasılık eğrisi

26–30 dk — **Raporlama ve sorular**
lm ve GLM karşılaştırması

ÖĞRENİM KAZANIMLARI

- Sayım ve var/yok verisinde neden GLM gerektiğini açıklamak
- `glm(..., family = poisson / binomial)` modellerini kurmak
- Log bağlantılı katsayıları `exp()` ile **oran** olarak yorumlamak
- Sapma (deviance) ve olabilirlik oranı testini (`drop1`) okumak
- Aşırı saçılmayı hesaplamak ve negatif binom ile karşılaştırmak

PROBLEM

Tür sayımı neden normal dağılmaz?

- Sayımlar **0 veya pozitif tam sayıdır**: 0, 1, 2, … Negatif birey olmaz.
- Çok sayıda **sıfır** ve sağa çarpık dağılım tipiktir.
- Ortalama arttıkça **varyans da artar** (16. derste gördüğümüz huni biçimi).
- Var/yok verisi yalnızca **0 ve 1**'dir; tahmin bir **olasılık** olmalı (0–1 arası).
- `lm()` bunların hiçbirini bilmez: negatif sayım ya da 1'den büyük olasılık tahmin edebilir, standart hataları yanlış olur.

Çözüm: GLM

Yanıtın **dağılımını** (Poisson, binom…) ve ortalamanın açıklayıcılarla **nasıl bağlandığını** (log, logit) açıkça modele yazarız.

Bu derste yalnızca vegan'ın hazır verileri: `BCI` (Barro Colorado ağaç sayımları) ve `mite` (akar sayımları) + `MASS::glm.nb()`.

GLM'NİN ÜÇ PARÇASI

Model = dağılım + bağlantı + doğrusal öngörücü

PARÇA	ANLAMI	ÖRNEK
Dağılım (`family`)	Yanıt hangi süreçten geliyor?	Poisson (sayım)
Bağlantı (`link`)	Ortalamayı doğrusal ölçeğe çevirir	log(μ)
Doğrusal öngörücü	$b_0 + b_1x_1 + b_2x_2 \ldots$	EnvHet + Habitat

> Poisson: **$\log(\mu) = b_0 + b_1x$** → $\mu = e^{(b_0 + b_1x)}$. Böylece tahmin edilen sayım **her zaman pozitif**.

YANIT TÜRÜ	`FAMİLY`	BAĞLANTI	KATSAYI YORUMU
Sürekli	gaussian	identity	Fark (lm ile aynı)
Sayım	poisson	log	exp(b) = **oran**
Aşırı saçılmış sayım	`MASS::glm.nb`	log	exp(b) = oran
Var / yok (0/1)	binomial	logit	exp(b) = **odds oranı**

R ARAÇ KUTUSU

Bu derste kullanacağımız fonksiyonlar

FONKSİYON	NE YAPAR?
`glm(y ~ x, data = env, family = poisson)`	Poisson GLM (varsayılan bağlantı: log)
`exp(coef(m))`	Log ölçeğindeki katsayıları **çarpan / oran** ölçeğine çevirir
`predict(m, newdata, type = "response")`	Beklenen sayım / olasılık (`type = "link"` → log ölçeği)
`drop1(m, test = "Chisq")`	Her terimi çıkarınca sapma ne kadar artıyor? (olabilirlik oranı testi)
`residuals(m, type = "pearson")`, `df.residual(m)`	Aşırı saçılma oranı için
`MASS::glm.nb(y ~ x)`	Negatif binom GLM: varyans > ortalama durumuna izin verir
`glm(..., family = binomial)`	Lojistik regresyon (var/yok)

BÖLÜM 1

Poisson GLM: vegan::BCI

Panama, 50 adet 1 ha'lık parsel: Adelia triloba ağaç sayısı habitat ve çevreyle nasıl değişiyor?

VERİYİ TANI

Sayım verisi, sıfırlar ve dengesiz gruplar

```
library(vegan)
data(BCI); data(BCI.env)
y <- BCI$Adelia.triloba              # yanıt: parsel başına ağaç sayısı

identical(rownames(BCI), rownames(BCI.env))
summary(y)
c(ortalama = mean(y), varyans = var(y))
table(BCI.env$Habitat)
```

ÇIKTI

```
[1] TRUE
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   0.00    0.00    1.00    1.84    2.00   14.00
ortalama  varyans
1.840000 8.177959

 OldHigh   OldLow OldSlope    Swamp    Young
       8       26       12        2        2
```

- Medyan 1, en çok 14: **sağa çarpık**, çok sayıda 0.
- Varyans (**8.2**) ortalamanın (**1.8**) 4 katından fazla. Poisson **varyans = ortalama** varsayar → aşırı saçılma şüphesi.
- Swamp ve Young habitatlarında yalnızca **2'şer** parsel var: bu grupların katsayıları **çok belirsiz** olacak.

> Bu üç gözlem, modeli kurmadan önce sonuçları nasıl okuyacağımızı belirliyor.

SUMMARY(GLM)

Katsayılar log ölçeğinde

```
glm1 <- glm(y ~ EnvHet + Habitat + Stream, data = BCI.env,
            family = poisson(link = "log"))
summary(glm1)
```

ÇIKTI

```
Coefficients:
               Estimate Std. Error z value Pr(>|z|)
(Intercept)       1.4162     0.2228   6.357 2.06e-10 ***
EnvHet            0.4363     0.4419   0.987   0.3234
HabitatOldLow    -1.4734     0.2689  -5.478 4.29e-08 ***
HabitatOldSlope  -1.6626     0.3763  -4.418 9.94e-06 ***
HabitatSwamp     -2.3893     1.0215  -2.339   0.0193 *
HabitatYoung      0.6779     0.2828   2.397   0.0165 *
StreamYes        -1.3217     0.7364  -1.795   0.0727 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for poisson family taken to be 1)

    Null deviance: 175.652  on 49  degrees of freedom
Residual deviance:  82.643  on 43  degrees of freedom
AIC: 172.39
```

- Referans grup: **OldHigh** habitatı, akarsu **yok** (alfabetik ilk düzeyler).
- `HabitatOldLow = −1.47`: OldLow'da log(beklenen sayım), OldHigh'tan 1.47 **düşük**.
- **z value / Pr(>|z|)**: Wald testi (lm'deki t testinin karşılığı).
- EnvHet (p = 0.32) bu modelde belirgin katkı yapmıyor.
- **Null deviance 175.7 → Residual deviance 82.6**: açıklayıcılar sapmanın yaklaşık **%53**'ünü açıklıyor (sözde R^2).

EXP(KATSAYI)

Log ölçeğinden anlaşılır orana

```
round(exp(coef(glm1)), 2)

yeni <- data.frame(EnvHet = mean(BCI.env$EnvHet), Stream = "No",
                   Habitat = c("OldHigh", "OldLow", "OldSlope", "Young"))
round(predict(glm1, newdata = yeni, type = "response"), 1)
```

ÇIKTI

```
    (Intercept)          EnvHet   HabitatOldLow HabitatOldSlope
           4.12            1.55            0.23            0.19
   HabitatSwamp    HabitatYoung       StreamYes
           0.09            1.97            0.27
  1   2   3   4
4.7 1.1 0.9 9.3
```

TERİM	EXP(B)	YORUM
HabitatOldLow	0.23	OldHigh'a göre **%77 daha az** ağaç
HabitatOldSlope	0.19	%81 daha az
HabitatYoung	1.97	Yaklaşık **2 kat** fazla (ama n = 2!)
StreamYes	0.27	Akarsu olan parsellerde %73 daha az (p = 0.07)

- `predict(..., type = "response")` beklenen **sayımı** verir: OldHigh'ta ≈ 4.7, OldLow'da ≈ 1.1 ağaç/parsel.
- Diğer değişkenler **sabitken** yorumlanır (15. ders).

OLABİLİRLİK ORANI TESTİ

Hangi terim gerçekten gerekli?

```
drop1(glm1, test = "Chisq")
```

ÇIKTI

```
Single term deletions

Model:
y ~ EnvHet + Habitat + Stream
        Df Deviance    AIC    LRT Pr(>Chi)
<none>       82.643 172.39
EnvHet   1   83.615 171.36  0.972  0.32420
Habitat  4  153.495 235.24 70.853  1.5e-14 ***
Stream   1   87.340 175.08  4.698  0.03021 *
```

- `drop1()` her terimi **tek tek çıkarıp** sapmanın ne kadar arttığına bakar (**LRT**).
- **Habitat** çıkarılınca sapma 82.6 → **153.5** (LRT = 70.9, 4 sd, p < 0.001): en önemli terim.
- **Stream**: LRT = 4.7, p = 0.03.
- **EnvHet**: LRT = 0.97, p = 0.32; çıkarılınca AIC **düşüyor** (172.4 → 171.4).
- Kategorik değişkenin **tüm düzeylerini birlikte** test eder: Wald testlerinden daha güvenilir.

> AIC sütunu 22. dersin konusudur: modeller arasında uyum ve sadelik dengesi.

AŞIRI SAÇILMA

Poisson varsayımı tutuyor mu?

```
sacilma <- sum(residuals(glm1, type = "pearson")^2) / df.residual(glm1)
sacilma

library(MASS)
glm_nb <- glm.nb(y ~ EnvHet + Habitat + Stream, data = BCI.env)
round(cbind(Poisson_p = summary(glm1)$coef[, 4],
            NegBin_p  = summary(glm_nb)$coef[, 4]), 4)
```

ÇIKTI

```
[1] 1.984469
                Poisson_p NegBin_p
(Intercept)        0.0000   0.0001
EnvHet             0.3234   0.3947
HabitatOldLow      0.0000   0.0001
HabitatOldSlope    0.0000   0.0005
HabitatSwamp       0.0193   0.0333
HabitatYoung       0.0165   0.3039
StreamYes          0.0727   0.0887
```

- **Saçılma oranı** = Pearson ki-kare / artık sd. Poisson'da ≈ **1** olmalı.
- **1.98**: varyans beklenenin yaklaşık 2 katı → Poisson standart hataları **fazla küçük**, p-değerleri **fazla iyimser**.
- **Negatif binom** varyansın ortalamadan hızlı artmasına izin verir.
- Sonuç: Young habitatı Poisson'da "anlamlı" (p = 0.017), NB'de **değil** (p = 0.30). Habitatın OldLow/OldSlope etkisi ise sağlam.

> Aşırı saçılma varsa yalnızca Poisson p-değerlerine dayanarak sonuç yazılmaz. Nedenini de araştırın: eksik açıklayıcı, gözlem bağımlılığı, fazla sıfır.

BÖLÜM 2

Lojistik GLM: vegan::mite

70 turba yosunu karotu: Galumna akarı bulunuyor mu? Su içeriği (WatrCont) bunu nasıl etkiliyor?

Katsayı → odds oranı → olasılık eğrisi

```
data(mite); data(mite.env)
var_yok <- as.integer(mite$Galumna1 > 0)     # 1 = var, 0 = yok
table(var_yok)

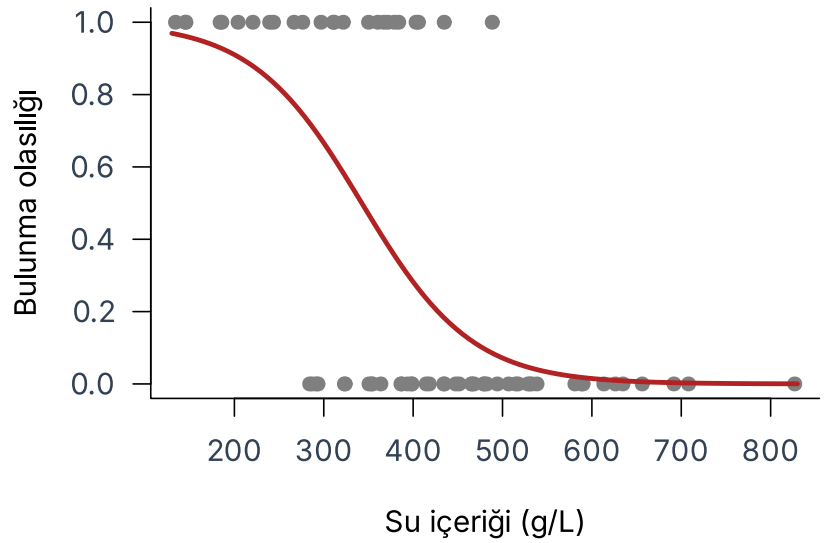
glm_b <- glm(var_yok ~ WatrCont, data = mite.env, family = binomial)
round(summary(glm_b)$coef, 4)
exp(coef(glm_b)["WatrCont"] * 100)           # 100 g/L artışın etkisi
```

ÇIKTI

```
var_yok
 0  1
45 25
            Estimate Std. Error z value Pr(>|z|)
(Intercept)   5.5718     1.5235  3.6572    3e-04
WatrCont     -0.0163     0.0041 -3.9777    1e-04
 WatrCont
0.1965907
```

- Eğim −0.016 ($p < 0.001$): su içeriği arttıkça bulunma **logit**'i azalıyor.
- **Odds oranı**: su içeriği **100 g/L** artınca bulunma odds'u **0.20 katına** iner (%80 azalır).

```
plot(mite.env$WatrCont, var_yok, pch = 19, col = "grey50",
     xlab = "Su içeriği (g/L)", ylab = "Bulunma olasılığı")
x <- seq(130, 830, length.out = 100)
lines(x, predict(glm_b, data.frame(WatrCont = x), type = "response"),
      col = "firebrick", lwd = 3)
```



Eğri 0–1 arasında kalır: lm'nin aksine **anlamsız olasılık** üretmez. Galumna **kuru** karotlarda daha olası.

KARŞILAŞTIRMA VE RAPORLAMA

lm ile GLM yan yana

	DOĞRUSAL REGRESYON `lm()`	GLM `glm()`
Yanıt	Sürekli, sınırsız	Sayım (Poisson/NB), 0/1 (binom) …
Varyans	Sabit	Ortalamaya bağlı (Poisson: varyans = ortalama)
Katsayı	Doğrudan fark	Bağlantı ölçeğinde → `exp()` ile oran / odds oranı
Uyum ölçüsü	R^2, F	Sapma (deviance), LRT, AIC
Kontrol	Artık grafikleri	Pearson artıkları, **aşırı saçılma**

Rapor cümlesi: "Adelia triloba sayımı Poisson GLM (log bağlantı) ile modellenmiştir. Habitat en güçlü açıklayıcıdır (LRT χ^2 = 70.9, sd = 4, $p < 0.001$); OldLow ve OldSlope habitatlarında beklenen sayım OldHigh'a göre sırasıyla %77 ve %81 düşüktür. Saçılma oranı 1.98 olduğundan negatif binom model de kurulmuş; habitat etkisi korunmuş, Young habitatının etkisi (n = 2) anlamlılığını yitirmiştir."

KENDİNİ SINA

Ölçme ve değerlendirme

1. Sayım verisi için `lm()` kullanmanın üç sorunu nedir?
2. Poisson katsayısı −1.47 ise `exp(−1.47) = 0.23` cümle olarak nasıl yorumlanır?
3. `drop1(test = "Chisq")` neyi test eder? Wald testinden farkı nedir?
4. Saçılma oranı 1.98 ne anlama gelir, ne yapılmalıdır?
5. Lojistik regresyonda odds oranı 0.20 nasıl yorumlanır?

ÖZET

Akılda kalması gerekenler

- GLM = **dağılım** (`family`) + **bağlantı** (log, logit) + doğrusal öngörücü.
- Sayım → `poisson`; aşırı saçılmış sayım → `MASS::glm.nb`; var/yok → `binomial`.
- Katsayıyı `exp()` ile **oran / odds oranı** olarak yorumla; `predict(type = "response")` ile sayım/olasılık.
- Terim testi için `drop1(test = "Chisq")` (LRT); uyum için sapma.
- Saçılma oranını **her zaman** hesapla: ≈ 1 değilse p-değerlerine güvenme.