30 dakika

23

Çok Değişkenli Analizlerde Veri Hazırlama

Analize başlamadan önce: yapı, eşleşme, eksik değer, sıfırlar, dönüşüm, ölçek, çoklu bağlantı ve grup yayılımı

---

5 günlük program · 5. gün · 3. ders saati (bonus konu ve program sentezi)

Gürçay Kıvanç AKYILDIZ

Pamukkale Üniversitesi · Fen Fakültesi · Biyoloji Bölümü

DERS PLANI

30 dakikada neler yapacağız?

0–4 dk — **Ana mesaj**
Analiz sonucu, verinin hazırlanışından daha iyi olamaz

4–11 dk — **Yapı, eşleşme, eksik değer**
mite, airquality

11–17 dk — **Topluluk matrisi**
Sıfırlar, örnek toplamları, baskın türler, Hellinger

17–24 dk — **Çevresel tablo**
Ölçek, VIF, n / p oranı (varechem)

24–30 dk — **Grup karşılaştırması ve sentez**
PERMANOVA + betadisper, kontrol listesi

ÖĞRENİM KAZANIMLARI

- Analiz öncesi kontrol listesini R kodlarıyla uygulamak
- Topluluk ve çevre tablolarının eşleştiğini doğrulamak
- Sıfır yoğunluğu ve baskın türlerin etkisini görmek, dönüşüm seçmek
- VIF ve düzeltilmiş R^2 ile aşırı yüklenmiş modeli fark etmek
- PERMANOVA sonucunu yayılım (dispersion) kontrolüyle birlikte yorumlamak

ANA MESAJ

Analizden önce on soru

#	SORU	R İLE KONTROL
1	Satırlar aynı alanları mı temsil ediyor?	`identical(rownames(tur), rownames(env))`
2	Değişken türleri doğru mu (sayı, faktör, sıralı)?	`str()`
3	Eksik değer var mı, analiz kaç gözlemi kaybediyor?	`colSums(is.na())`, `complete.cases()`
4	Boş satır/sütun, nadir tür var mı?	`rowSums()`, `colSums(x > 0)`
5	Birkaç baskın tür analizi domine ediyor mu?	`sapply(x, var)`, `decostand()`
6	Değişkenler farklı birimlerde mi?	`sapply(env, var)` → `scale`
7	Açıklayıcılar birbirinin kopyası mı?	`cor()`, `vif.cca()`
8	Gözlem sayısı açıklayıcı sayısına yetiyor mu?	`RsquareAdj()`
9	Gruplar farklı mı, yoksa yalnızca yayılımları mı?	`adonis2()` + `betadisper()`
10	Gözlemler bağımsız mı?	Örnekleme tasarımı, `permute::how()`

BÖLÜM 1

Yapı, eşleşme ve eksik değer

vegan::mite (70 karot × 35 akar türü + çevre) ve datasets::airquality

YAPI VE EŞLEŞME

str() her analizin ilk satırıdır

```
library(vegan)
data(mite); data(mite.env)

dim(mite)
identical(rownames(mite), rownames(mite.env))
str(mite.env)
```

ÇIKTI

```
[1] 70 35
[1] TRUE
'data.frame':   70 obs. of  5 variables:
 $ SubsDens : num  39.2 55 46.1 48.2 23.6 ...
 $ WatrCont : num  350 435 372 360 204 ...
 $ Substrate: Factor w/ 7 levels "Sphagn1","Sphagn2",..: 1 5 7 1 1 1 1 7 5 1 ...
 $ Shrub    : Ord.factor w/ 3 levels "None"<"Few"<"Many": 2 2 2 2 2 2 2 3 3 3 ...
 $ Topo     : Factor w/ 2 levels "Blanket","Hummock": 2 2 2 2 2 2 2 1 1 2 ...
```

- Topluluk ve çevre tablosu **aynı 70 karotu**, **aynı sırada** içeriyor (`TRUE`).
- **SubsDens**, **WatrCont**: sürekli (`num`).
- **Substrate**, **Topo**: kategorik (`Factor`).
- **Shrub**: **sıralı faktör** (`Ord.factor` : None < Few < Many). Modellerde **polinom karşıtlıkları** (`.L` , `.Q`) olarak girer; 20. derste `Moisture` için gördük.

> Sıralı faktörü düz faktör olarak kullanmak istiyorsanız: `factor(x, ordered = FALSE)` . Bu bir **karar**dır ve raporlanmalıdır.

EKSİK DEĞER

Kayıp, hangi değişkenleri seçtiğinize bağlıdır

```r
colSums(is.na(airquality))

nrow(airquality)
sum(complete.cases(airquality))                          # tüm değişkenler
sum(complete.cases(airquality[, c("Ozone", "Temp")]))    # yalnız ikisi
```

ÇIKTI

```
  Ozone Solar.R    Wind    Temp   Month     Day
     37       7       0       0       0       0
[1] 153
[1] 111
[1] 116
```

- NA'lar **Ozone** (37) ve **Solar.R** (7) sütunlarında.
- Tüm değişkenlerle analiz → **111** gün (%27 kayıp). Yalnız Ozone + Temp → **116** gün.
- `prcomp()`, `rda()` NA kabul etmez; `lm()` ve `glm()` **sessizce** satır siler.
- Farklı gözlem sayılı modeller **AIC ile karşılaştırılamaz** (22. ders).

> Önce **ortak veri setini** kurun ve tüm analizleri onunla yapın. Kayıp rastgele değilse (örn. cihaz arızası belirli hava koşullarında) sonuçlar yanlı olabilir; bunu raporlayın.

BÖLÜM 2

Topluluk matrisi

Sıfırlar, örnek toplamları ve baskın türler

Topluluk verisinin iki doğal özelliği

```
round(mean(mite == 0), 2)            # hücrelerin ne kadarı sıfır?
summary(rowSums(mite))               # karot başına toplam birey
sort(colSums(mite > 0))[1:5]         # en nadir türler (karot sayısı)
```

ÇIKTI

```
[1] 0.57
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   8.00   97.75  121.00  140.00  161.00  781.00
    MPRO     PPEL Lepidzts     SSTR Miniglmn
       8        8        8        9        9
```

%57 sıfır

Çift sıfır sorunu: iki karotta **birlikte bulunmayan** tür, onları benzer göstermemeli. Bu yüzden ham veriyle **öklit** temelli yöntemler (PCA, RDA) uygun değildir → Hellinger veya Bray–Curtis.

8 – 781 birey

Karot toplamları **100 kat** farklı. Fark gerçek bolluk mu, örnekleme çabası mı? Oransal dönüşüm (`"total"`, `"hellinger"`) toplam etkisini kaldırır.

- En nadir tür 8 karotta: bu veride **çok nadir** tür yok; CA öncesi duyarlılık sorunu küçük (17. ders).

BASKIN TÜRLER

Üç tür toplam varyansın %79'u: dönüşüm ne değiştirir?

```
data(varespec)
v_ham <- sapply(varespec, var)
round(100 * sort(v_ham, decreasing = TRUE)[1:3] / sum(v_ham), 1)

v_hel <- sapply(decostand(varespec, "hellinger"), var)
round(100 * sort(v_hel, decreasing = TRUE)[1:3] / sum(v_hel), 1)
```

ÇIKTI

```
Cladstel Pleuschr Cladrang
    47.1     19.6     12.2
Cladstel Pleuschr Cladrang
    25.8     15.6      8.7
```

- `sapply(x, var)` her türün varyansını; payı ise türün analize **ne kadar ağırlık** koyacağını gösterir.
- Ham varespec'te üç liken/yosun (Cladstel, Pleuschr, Cladrang) toplam varyansın **%79**'u: PCA/RDA neredeyse yalnızca bu üç türü görür.
- Hellinger sonrası aynı üç türün payı **%50**: diğer 41 tür de analize katılır.

DÖNÜŞÜM (`DECOSTAND`)	NE ZAMAN?
`"hellinger"`	PCA/RDA öncesi topluluk verisi (en yaygın)
`"total"`	Göreli bolluk (oran)
`"pa"`	Yalnızca var/yok bilgisi
`log1p()`	Büyük bollukları bastırmak

BÖLÜM 3

Çevresel tablo

vegan::varechem: 24 alan, 14 değişken. Hepsini modele koymak iyi bir fikir mi?

ÇOKLU BAĞLANTI

vif.cca(): 14 değişkenin hepsi birden

```
data(varechem)
tum   <- rda(varespec ~ ., data = varechem)        # 14 açıklayıcı
round(vif.cca(tum), 1)

secili <- rda(varespec ~ N + P + K + Al + pH + Humdepth + Baresoil,
              data = varechem)                     # 7 açıklayıcı
round(vif.cca(secili), 1)
```

ÇIKTI

```
       N        P        K       Ca       Mg        S       Al       Fe
     1.9      6.2     11.7      9.8      9.6     18.5     20.3      8.8
      Mn       Zn       Mo Baresoil Humdepth       pH
     5.2      7.8      4.6      2.2      5.6      6.9
       N        P        K       Al       pH Humdepth Baresoil
     1.1      2.7      3.0      1.6      2.3      2.7      1.7
```

- `~ .` = "tablodaki **tüm** sütunlar". Pratik ama tehlikeli.
- Tüm modelde **Al 20.3, S 18.5, K 11.7**: bu değişkenler büyük ölçüde diğerlerinden tahmin edilebiliyor.
- Ekolojik gerekçeyle seçilmiş 7 değişkende tüm VIF'ler **< 3**.
- Yüksek VIF → eksen ve katsayılar **kararsız**; hangi değişkenin "önemli" olduğu yorumlanamaz.

> Seçimi **VIF'e göre otomatik** değil, ekolojik soruya göre yapın; VIF yalnızca bir uyarı ışığıdır.

N / P ORANI

24 alana 14 açıklayıcı: R^2 neden yanıltıcı?

```
round(unlist(RsquareAdj(tum)), 2)       # 14 açıklayıcı, 24 alan
round(unlist(RsquareAdj(secili)), 2)    #  7 açıklayıcı, 24 alan
```

ÇIKTI

```
    r.squared adj.r.squared
         0.80          0.49
    r.squared adj.r.squared
         0.58          0.40
```

23 serbestlik derecesinin 14'ü açıklayıcılara gidiyor: model **neredeyse her şeye** uyabilir.

MODEL	R^2	DÜZ. R^2	FARK
14 açıklayıcı	0.80	0.49	**0.31**
7 açıklayıcı	0.58	0.40	0.18

- Ham R^2 ile düzeltilmiş R^2 arasındaki **büyük fark**, aşırı yüklenmiş modelin işaretidir.
- Tüm model düzeltilmiş R^2'de hâlâ yüksek görünse de VIF'ler ve küçük n nedeniyle **yorumlanamaz**.
- Kaba kural: açıklayıcı sayısı, alan sayısının **üçte birini** geçmesin; ileri adım seçim (`ordistep()`) ancak önceden tanımlı adaylarla.

BÖLÜM 4

Grup karşılaştırması

PERMANOVA anlamlı: gruplar farklı mı, yoksa yayılımları mı?

PERMANOVA + BETADİSPER

İki test birlikte okunur

```
data(dune); data(dune.env)
set.seed(1)
adonis2(dune ~ Management, data = dune.env, method = "bray",
        permutations = 999)

yayilim <- betadisper(vegdist(dune, method = "bray"), dune.env$Management)
set.seed(1)
permutest(yayilim, permutations = 999)
round(tapply(yayilim$distances, dune.env$Management, mean), 2)
```

ÇIKTI

```
           Df SumOfSqs      R2      F Pr(>F)
Management  3   1.4686 0.34161 2.7672  0.002 **
Residual   16   2.8304 0.65839
Total      19   4.2990 1.00000
```

ÇIKTI

```
          Df  Sum Sq  Mean Sq      F N.Perm Pr(>F)
Groups     3 0.13831 0.046104 1.9506    999  0.154
Residuals 16 0.37816 0.023635
```

ÇIKTI

```
  BF   HF   NM   SF
0.22 0.28 0.45 0.36
```

TEST	SONUÇ	ANLAMI
`adonis2`	R^2 = 0.34, p = 0.002	Yönetim tipi Bray–Curtis farkının **%34**'ünü açıklıyor
`betadisper`	F = 1.95, p = 0.15	Grupların **yayılımları** anlamlı farklı değil

- PERMANOVA hem **merkez** farkına hem **yayılım** farkına duyarlıdır.
- Yayılım farkı yoksa PERMANOVA sonucu **merkez** (bileşim) farkı olarak yorumlanabilir.
- NM'nin yayılımı (0.45) en büyük; fark anlamlı değil ama grup büyüklükleri küçük (3–6 alan).

SENTEZ

Program boyunca kullandığımız kontrollerin özeti

AŞAMA	KONTROL	DERS
Veri	`str()`, `identical(rownames())`, `colSums(is.na())`	3–4, 23
Dağılım	Grafik, `shapiro.test()`, ortalama–varyans ilişkisi	2, 16, 21
Model biçimi	Artık grafikleri, dönüşüm	16
Topluluk	`decostand()`, DCA eksen uzunluğu, nadir türler	17, 20
Çevre	`scale`, `cor()`, `vif.cca()`, `RsquareAdj()`	15, 18, 19
Çıkarım	Permütasyon (`set.seed`), aşırı saçılma, AIC koşulları	19–22

Rapor şablonu: "Analizden önce tabloların eşleşmesi, eksik değerler (n = ...), sıfır oranı (%...), dönüşüm (Hellinger), açıklayıcı VIF değerleri (< ...) ve grup yayılımları (betadisper p = ...) kontrol edilmiştir."

KENDİNİ SINA

Ölçme ve değerlendirme

1. Topluluk ve çevre tablosunun satır sırası kayarsa analiz hata verir mi? Nasıl kontrol edilir?
2. mite verisinde %57 sıfır olması hangi yöntemleri ham veriyle uygunsuz kılar?
3. Ham varespec'te üç türün varyansın %79'unu taşıması PCA'yı nasıl etkiler?
4. $R^2 = 0.80$, düzeltilmiş $R^2 = 0.49$ olan bir modelden ne anlarsınız?
5. PERMANOVA $p = 0.002$, betadisper $p = 0.15$: sonuç nasıl yorumlanır?

ÖZET

Akılda kalması gerekenler

- İlk satır her zaman `str()` ve `identical(rownames(...))`.
- NA kaybını ölç ve tüm analizleri **aynı gözlemlerle** yap.
- Topluluk verisi: sıfırlar ve baskın türler → `decostand("hellinger")` / Bray–Curtis.
- Çevre verisi: `scale`, `vif.cca()` < 10, **düzeltilmiş R^2**; az alana çok açıklayıcı koyma.
- PERMANOVA'yı **betadisper** ile birlikte raporla.