30 dakika

24

GLM, PCA, RDA ve CCA: Hangi Soru, Hangi Yöntem?

Aynı ekolojik veri üzerinde dört yöntemi yan yana kurmak, okumak ve doğru olanı seçmek

---

5 günlük program · Program sonu sentez dersi

Gürçay Kıvanç AKYILDIZ

Pamukkale Üniversitesi · Fen Fakültesi · Biyoloji Bölümü

DERS PLANI

30 dakikada neler yapacağız?

0–4 dk — **Dört yöntem, dört soru**
Karşılaştırma tablosu ve R araç kutusu

4–10 dk — **PCA: dune**
Desen nedir? (çevre yok)

10–20 dk — **RDA ve CCA: dune + dune.env**
Aynı formül, iki geometri, farklı sonuçlar

20–26 dk — **GLM: mite**
Tek bir taksonun sayımı çevreyle nasıl değişir?

26–30 dk — **Karar özeti ve sorular**
Kendini sına

ÖĞRENİM KAZANIMLARI

- GLM, PCA, RDA ve CCA'nın yanıtladığı soruları ayırt etmek
- Aynı veriyle PCA, RDA ve CCA kurup çıktılarını karşılaştırmak
- RDA ve CCA'nın neden farklı sonuç verebileceğini açıklamak
- Tek bir taksonun sayımı için GLM kurup yorumlamak
- Araştırma sorusundan yola çıkarak yöntem seçmek

TEMEL FARKLAR

Dört yöntem tek tabloda

ÖZELLİK	GLM	PCA	RDA	CCA
Tür	Regresyon	Kısıtsız ordinasyon	Kısıtlı ordinasyon	Kısıtlı ordinasyon
Yanıt	**Tek** değişken	Çok değişkenli matris	Çok değişkenli matris	Çok değişkenli matris
Açıklayıcı	Var	**Yok**	Var	Var
Geometri	Dağılım ailesi + bağlantı	Öklit	Öklit	Ki-kare
Tür tepkisi	Modele yazılır	Doğrusal	Doğrusal	Tepe biçimli (unimodal)
Test	Wald, LRT	Yok (betimsel)	Permütasyon	Permütasyon
Tipik soru	Bir taksonun bolluğu nasıl değişir?	İstasyonlar nasıl farklılaşır?	Topluluğu hangi faktörler açıklar?	Topluluk gradyanlarla nasıl ilişkili?

R ARAÇ KUTUSU

Dört yöntem, dört fonksiyon ailesi

YÖNTEM	R KODU
PCA	`rda(tur_hel)` (formülsüz)
RDA	`rda(tur_hel ~ x1 + x2, data = env)`
CCA	`cca(tur ~ x1 + x2, data = env)`
GLM	`glm(y ~ x1 + x2, data = env, family = poisson)`
Yöntem seçimi	`decorana(tur)` → eksen uzunluğu

ORTAK YARDIMCILAR	NE YAPAR?
`decostand(x, "hellinger")`	Topluluk verisini öklit yöntemlerine hazırlar
`eigenvals()`	Eksenlerin açıkladığı pay
`RsquareAdj()`	Düzeltilmiş R^2
`anova(m, by = "margin")`	Permütasyonla terim testi
`MASS::glm.nb()`	Aşırı saçılmış sayımlar için GLM

Bu derste yalnızca vegan'ın hazır verileri: **dune / dune.env** (kumul çayırları, 20 alan × 30 tür) ve **mite / mite.env** (turba yosunu akarları, 70 karot × 35 tür).

BÖLÜM 1

PCA: desen nedir?

Çevre bilgisi kullanmadan alanlar tür bileşimine göre nasıl ayrışıyor?

PCA

Hellinger dönüşümlü tür bileşiminin ana eksenleri

```
library(vegan)
data(dune); data(dune.env)

dim(dune)
identical(rownames(dune), rownames(dune.env))
head(dune.env, 3)
```

ÇIKTI

```
[1] 20 30
[1] TRUE
   A1 Moisture Management      Use Manure
1 2.8        1         SF Haypastu      4
2 3.5        1         BF Haypastu      2
3 4.3        2         SF Haypastu      4
```

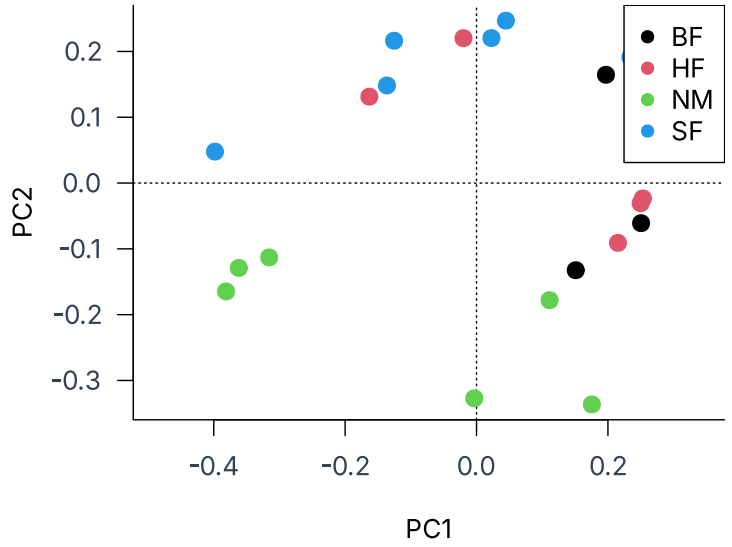
```
dune_hel <- decostand(dune, method = "hellinger")
pca <- rda(dune_hel)                    # formül yok → PCA

eig <- eigenvals(pca)
round(100 * eig[1:3] / sum(eig), 1)     # % varyans
```

ÇIKTI

```
 PC1  PC2  PC3
30.6 20.0 10.1
```

```
plot(pca, scaling = 1, display = "sites", type = "n")
points(pca, scaling = 1, display = "sites", pch = 19, cex = 1.4,
       col = as.integer(dune.env$Management))
legend("topright", levels(dune.env$Management), col = 1:4, pch = 19)
```



- PC1 **%30.6**, PC2 **%20.0**: iki eksen bileşimin yarısını özetliyor.
- Renkleri (yönetim tipi) **sonradan** ekledik; PCA bu bilgiyi kullanmadı. NM alanları ayrışıyor gibi; ama bu bir **test değildir**.

BÖLÜM 2

RDA ve CCA: çevre ne kadar açıklıyor?

Aynı formül: tür ~ A1 + Moisture + Management

RDA

PCA + açıklayıcılar = kısıtlı doğrusal ordinasyon

```
rda1 <- rda(dune_hel ~ A1 + Moisture + Management, data = dune.env)

round(c(toplam   = rda1$tot.chi,
        aciklanan = rda1$CCA$tot.chi,
        kalan    = rda1$CA$tot.chi), 3)
round(unlist(RsquareAdj(rda1)), 3)

set.seed(1)
anova(rda1, by = "margin", permutations = 999)
```

ÇIKTI

```
   toplam aciklanan     kalan
    0.556     0.323     0.233
    r.squared adj.r.squared
        0.581         0.337
```

ÇIKTI

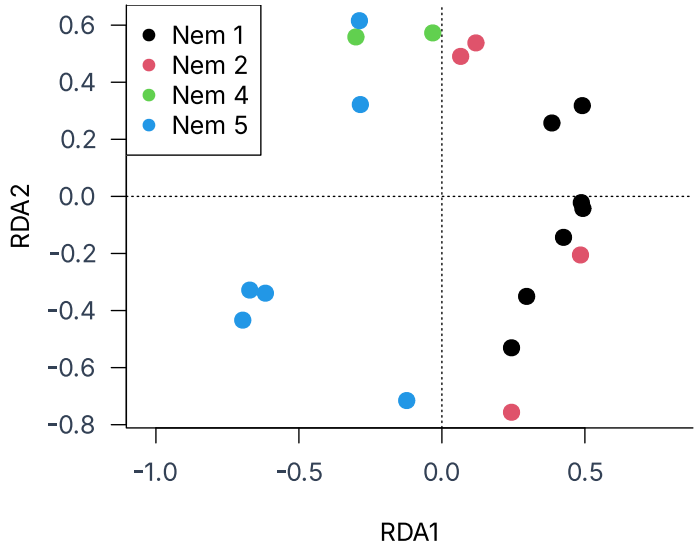
```
           Df Variance      F Pr(>F)
A1          1 0.024722 1.2751  0.259
Moisture    3 0.108874 1.8719  0.012 *
Management  3 0.108979 1.8737  0.014 *
Residual   12 0.232654
```

- Toplam varyans 0.556; çevresel değişkenlerle açıklanan **0.323**.
- R^2 = **0.58**, düzeltilmiş R^2 = **0.34**: 7 serbestlik derecesi ve 20 alan dikkate alınınca bileşimin yaklaşık üçte biri.
- Marjinal testler: **Moisture** (p = 0.012) ve **Management** (p = 0.014) diğerleri modeldeyken de katkı yapıyor; **A1** yapmıyor (p = 0.26).

> "Açıklanan / toplam = %58" nedensellik kanıtı değildir; **düzeltilmiş R^2** raporlanır.

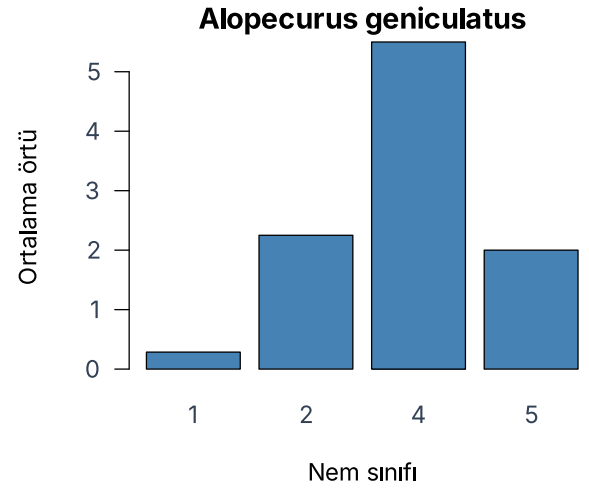
RDA ile CCA'yı ayıran varsayım

```
plot(rda1, scaling = 2, display = "sites", type = "n")
points(rda1, scaling = 2, display = "sites", pch = 19, cex = 1.4,
       col = as.integer(dune.env$Moisture))
legend("topleft", paste("Nem", levels(dune.env$Moisture)),
       col = 1:4, pch = 19)
```



- Alanları **nem sınıfına** göre renklendirdik: RDA1 boyunca kurudan (Nem 1) ıslağa (Nem 5) bir sıralanma var.

```
# Tek bir türün nem sınıflarına göre ortalama örtüsü
barplot(tapply(dune$Alopgeni, dune.env$Moisture, mean),
        xlab = "Nem sınıfı", ylab = "Ortalama örtü",
        main = "Alopecurus geniculatus", col = "steelblue")
```



- *Alopecurus geniculatus* en çok **orta-ıslak** (4) sınıfta: iki uçta az → **tepe biçimli** tepki.
- Bu tür tepkiler yaygınsa ki-kare temelli **CCA** daha uygun olabilir.

Aynı formül, ki-kare geometrisi

```
cca1 <- cca(dune ~ A1 + Moisture + Management, data = dune.env)

round(c(toplam = cca1$tot.chi, aciklanan = cca1$CCA$tot.chi), 3)
round(unlist(RsquareAdj(cca1)), 3)

set.seed(1)
anova(cca1, by = "margin", permutations = 999)
```

ÇIKTI

```
   toplam aciklanan
    2.115     1.139
    r.squared adj.r.squared
        0.539         0.269
```

ÇIKTI

```
           Df ChiSquare      F Pr(>F)
A1          1   0.13679 1.6817  0.075 .
Moisture    3   0.35939 1.4728  0.068 .
Management  3   0.39543 1.6205  0.024 *
Residual   12   0.97610
```

- Toplam inertia **2.115** (ki-kare); RDA'daki 0.556 ile **aynı ölçekte değil**: ham inertialar yöntemler arasında karşılaştırılmaz.
- R^2 = 0.54, düzeltilmiş R^2 = **0.27**.
- Marjinal testlerde yalnızca **Management** anlamlı (p = 0.024); Moisture (0.068) ve A1 (0.075) sınırda.

> CCA'da topluluk verisi **dönüştürülmez**: ham bolluklar kullanılır, ki-kare uzaklığı profilleri karşılaştırır.

Aynı veri, aynı formül, farklı sonuç

	RDA (HELLİNGER)	CCA (HAM)
Düzeltilmiş R^2	**0.34**	0.27
A1	p = 0.26	p = 0.075
Moisture	**p = 0.012**	p = 0.068
Management	**p = 0.014**	**p = 0.024**

- Her iki yöntem de **yönetim** etkisinde anlaşıyor; nem için sonuç yönteme bağlı.
- Fark, iki yöntemin bileşim farkını **farklı ölçmesinden** gelir (Hellinger–öklit vs ki-kare).

```
decorana(dune)
```

ÇIKTI

```
                        DCA1   DCA2    DCA3    DCA4
Eigenvalues           0.5117 0.3036 0.12125 0.14267
Additive Eigenvalues  0.5117 0.2985 0.12242 0.12984
Decorana values       0.5360 0.2869 0.08136 0.04814
Axis lengths          3.7004 3.1166 1.30055 1.47888
```

DCA1 = **3.70 SD** → 3–4 arası **gri bölge**: iki yöntem de savunulabilir. Yöntemi **analizden önce** seçin ve gerekçesini yazın; uygun sonucu veren yöntemi sonradan seçmeyin.

BÖLÜM 3

GLM: tek bir taksonun sayımı

Neden dune değil? dune değerleri 0–9 örtü skorudur, sayım değildir. Gerçek sayım verisi: vegan::mite

Poisson ile başla, aşırı saçılmayı kontrol et, gerekirse negatif binom

```
library(MASS)
data(mite); data(mite.env)
y <- mite$ONOV                      # Oppiella nova: karot başına birey sayısı

c(ortalama = mean(y), varyans = var(y))

g_pois <- glm(y ~ WatrCont + Topo, data = mite.env, family = poisson)
sum(residuals(g_pois, type = "pearson")^2) / df.residual(g_pois)

g_nb <- glm.nb(y ~ WatrCont + Topo, data = mite.env)
round(summary(g_nb)$coef, 4)
round(exp(coef(g_nb)["WatrCont"] * 100), 2)   # 100 g/L artış
round(exp(coef(g_nb)["TopoHummock"]), 2)
```

ÇIKTI

```
 ortalama   varyans
 17.27143 325.85280
[1] 10.06332
            Estimate Std. Error z value Pr(>|z|)
(Intercept)   4.1143     0.3576 11.5046    0e+00
WatrCont     -0.0044     0.0008 -5.7686    0e+00
TopoHummock   0.7181     0.2088  3.4394    6e-04
WatrCont
    0.64
TopoHummock
       2.05
```

- Varyans ortalamanın çok üstünde; Poisson saçılma oranı **10.1** (≫ 1) → **negatif binom** (`glm.nb`).
- **WatrCont**: su içeriği **100 g/L** artınca beklenen ONOV sayısı **0.64 katına** iner (%36 azalış), $p < 0.001$.
- **Topo**: tümsek (Hummock) karotlarda beklenen sayı, düz (Blanket) karotlara göre **2.05 kat**, $p < 0.001$.
- Katsayılar log ölçeğinde: `exp()` ile **çarpan** olarak yorumlanır.

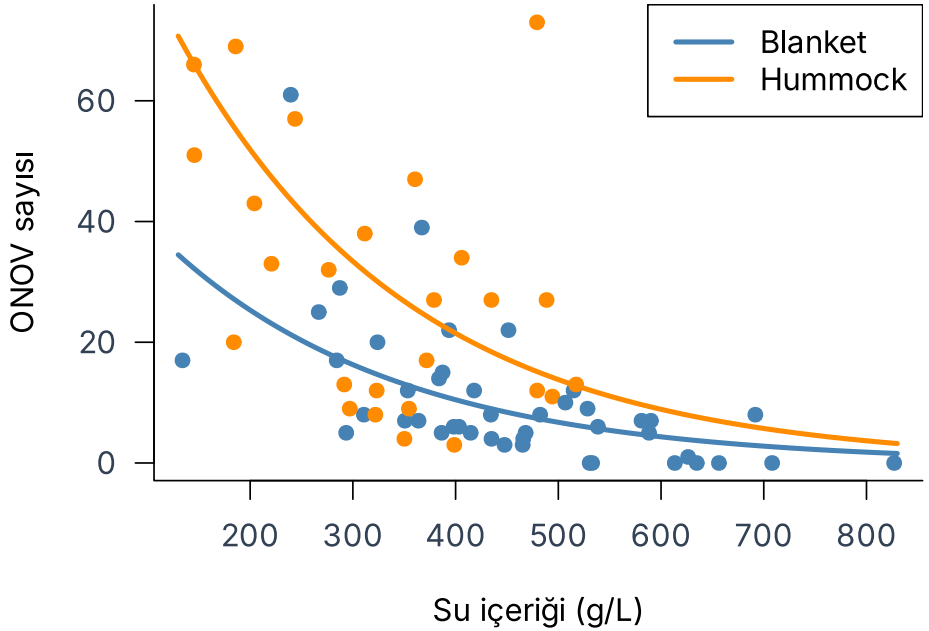
> Ordinasyon yöntemleri topluluğun **tamamına** bakar; GLM ise **tek bir türün** sayısını doğru dağılımla modeller ve tür bazında etki büyüklüğü verir.

GLM GRAFİĞİ

Model eğrisi: log bağlantı sayesinde hep pozitif

```
plot(y ~ WatrCont, data = mite.env, pch = 19,
     col = ifelse(mite.env$Topo == "Hummock", "darkorange", "steelblue"),
     xlab = "Su içeriği (g/L)", ylab = "ONOV sayısı")
x <- seq(130, 830, length.out = 100)
for (tp in c("Blanket", "Hummock"))
  lines(x, predict(g_nb, data.frame(WatrCont = x, Topo = tp), type = "response"),
        lwd = 3, col = ifelse(tp == "Hummock", "darkorange", "steelblue"))
legend("topright", c("Blanket", "Hummock"), col = c("steelblue", "darkorange"), lwd = 3)
```

- `predict(..., type = "response")` beklenen **sayımı** verir.
- Eğriler **paralel değil, oransal**: log ölçeğinde toplamsal etki, sayım ölçeğinde **çarpımsal** etkidir.
- Kuru ve tümsek karotlarda ONOV en bol; ıslak karotlarda neredeyse yok.



KARAR ÖZETİ

Araştırma sorusundan yönteme

ARAŞTIRMA SORUSU	OLASI YÖNTEM	R
Tür bileşiminin temel deseni nedir?	PCA (Hellinger), CA, NMDS, PCoA	`rda(x)`, `cca(x)`, `metaMDS()`
Topluluk çevresel değişkenlerle nasıl ilişkili? (kısa gradyan)	**RDA** + permütasyon	`rda(x ~ ..)`, `anova()`
Topluluk çevresel değişkenlerle nasıl ilişkili? (uzun gradyan)	**CCA** + permütasyon	`cca(x ~ ..)`, `anova()`
Tek bir taksonun sayısı çevreyle nasıl değişir?	Poisson / negatif binom **GLM**	`glm()`, `glm.nb()`
Tek bir yanıtta doğrusal olmayan ilişki	GAM veya polinom terimli GLM	`mgcv::gam()`
Tekrarlı ölçüm, istasyon etkisi	GLMM, kısıtlı permütasyon	`lme4::glmer()`, `how()`

Sonuç: PCA deseni gösterir; RDA ve CCA topluluk–çevre ilişkisini test eder; GLM tek bir yanıtı modeller. Aynı çalışmada **birbirini tamamlarlar**: örn. RDA ile hangi faktörlerin önemli olduğu, GLM ile gösterge taksonun bu faktörlere tepkisi.

KENDİNİ SINA

Ölçme ve değerlendirme

1. PCA ile RDA arasındaki tek fark nedir? R kodunda nasıl görünür?
2. RDA ve CCA'nın toplam inertia değerleri (0.556 ve 2.115) neden karşılaştırılamaz?
3. Aynı formülde nem RDA'da anlamlı, CCA'da sınırda çıktı. Bu nasıl raporlanmalı?
4. dune verisi GLM (Poisson) için neden uygun değildir?
5. ONOV için `exp(0.718) = 2.05` sonucu cümle olarak nasıl yorumlanır?

ÖZET

Akılda kalması gerekenler

- **PCA**: `rda(tur_hel)` → desen (çevre yok, test yok).
- **RDA**: `rda(tur_hel ~ çevre)` → doğrusal, Hellinger sonrası; düzeltilmiş R^2 + `anova()`.
- **CCA**: `cca(tur ~ çevre)` → ki-kare, tepe biçimli tepki; inertia RDA ile karşılaştırılmaz.
- **GLM**: `glm()` / `glm.nb()` → tek taksonun sayımı; `exp()` ile çarpan yorumu.
- Yöntemi soru, veri türü ve gradyan uzunluğu belirler; **analizden önce** seç.